دانشکده علوم ریاضی

پروژه درس تحلیل داده

پاییز ۱۴۰۵

شناسایی نارضایتی متنی

در نقدهای خدمات اشتراکی

ممیزی داده و تحلیل اکتشافی

مسیر ب: Amazon Reviews’23

محمدرضا استادعظیم

شماره دانشجویی: 401100025

گزارش فاز اول

تاریخ تهیه: ۱۰ آبان ۱۴۰۵، برابر با 2026-11-01

داده واقعی، محاسبات بازتولیدپذیر، تحلیل توصیفی روی بخش آموزش

۱. مسئله، تصمیم و دامنه مطالعه

این مطالعه نقدهای دو گروه «اشتراک مجله» و «بسته اشتراکی» را بررسی می‌کند. هدف کاربردی، کمک به تشکیل صف بررسی انسانی برای متن‌های حاکی از نارضایتی است، در وضعیتی که امتیاز ستاره‌ای در دسترس تحلیل‌گر نیست، مانند بازخورد واردشده از سامانه‌ای دیگر. در داده حاضر ستاره وجود دارد؛ آن را فقط برای تعریف یک برچسب مرجع ضعیف نگه می‌داریم و از ورودی مدل آینده حذف می‌کنیم. اگر ستاره معتبر در کاربرد واقعی موجود باشد، استفاده مستقیم از آن منطقی‌تر است.

سؤال منتخب این است: **آیا ترکیب متن نقد با ویژگی‌های محصول و زمینه ثبت نقد، در کالاهای دیده‌نشده، شناسایی نقدهای یک یا دو ستاره را نسبت به خط مبنای ثابت و متن تنها بهبود می‌دهد؟** فاز اول امکان‌پذیری این سؤال و محدودیت داده را مستند می‌کند؛ در این فاز مدل پیش‌بینی آموزش نداده‌ایم.

سه سؤال اولیه و دلیل انتخاب:

1. شناسایی برچسب نارضایتی در محصول دیده‌نشده با ترکیب متن و فراداده: سؤال اصلی، دارای معیار ارزیابی روشن و امکان مقایسه وجه‌ها.
2. رابطه طول نقد و خرید تأییدشده با فراوانی امتیاز پایین: سؤال توصیفی پشتیبان که در همین گزارش بررسی می‌شود.
3. پیش‌بینی رأی مفیدبودن: به فازهای بعد موکول می‌شود، زیرا زمان رسیدن رأی‌ها و دوره مواجهه یکسان در این نسخه موجود نیست.

متغیر هدف پیشنهادی:

$$y_i = \mathbb{1}\{r_i \leq 2\}, \qquad r_i \in \{1, 2, 3, 4, 5\}.$$

امتیازهای سه تا پنج، گروه مقایسه‌اند. سه ستاره می‌تواند معنای دوپهلو داشته باشد؛ تحلیل حساسیت آینده با حذف سه‌ستاره‌ها تعریف شده است. این برچسب، حقیقت شکایت، تقلب، نیاز به بازپرداخت یا رفتار آینده مشتری را نشان نمی‌دهد.

خلاصه شواهد: ورودی شامل 87,713 نقد است. پس از حذف 774 نسخه تکراری و قرنطینه 2 ردیف با کلید مبهم، 86,937 نقد باقی می‌ماند. ممیزی تصویر به وجود نشانی محدود است و هیچ قیمت عددی قابل استفاده‌ای نداریم. تمام تحلیل‌های مقدارمحور گزارش از 59,963 نقد آموزش به دست آمده است.

۲. منشأ داده و انتخاب زیرمجموعه

منبع، مجموعه عمومی Amazon Reviews’23 منتشرشده توسط آزمایشگاه مک‌آولی است. صفحه رسمی، نقد، امتیاز، زمان، رأی مفیدبودن و فراداده محصول را معرفی می‌کند و بازه کلی مجموعه را از ۱۹۹۶ تا سپتامبر ۲۰۲۳ می‌داند [1]. بازه زیرمجموعه حاضر از اکتبر ۲۰۰۱ تا اوت ۲۰۲۳ است و با بازه کل مجموعه یکسان نیست.

داده از نقدهای منتشرشده کاربران و اطلاعات گردآوری‌شده از صفحات محصول ساخته شده است. این داده **مشاهده‌ای** است. ثبت نقد تصادفی نیست و آزمایش کنترل‌شده‌ای در کار نیست. از داده موجود نمی‌توان تاریخچه کامل ویرایش متن، قیمت تاریخی، حذف نقدها یا زمان تک‌تک رأی‌های مفیدبودن را بازسازی کرد.

فایل رسمی	تعداد ردیف	حجم فشرده تقریبی
Magazine_Subscriptions، نقد	71,497	9.99 MB
Subscription_Boxes، نقد	16,216	2.70 MB
فراداده مجله	3,391	0.68 MB
فراداده بسته	641	0.28 MB

قاعده انتخاب، **تمام ردیف‌های همین دو دسته** است. هم‌خانواده‌بودن خدمات اشتراکی مقایسه را معنادار می‌کند و حجم محدود، اجرای روی رایانه شخصی را ممکن می‌سازد. هیچ نمونه‌گیری براساس امتیاز، تغییر دسته پس از دیدن عملکرد مدل، یا جایگزینی با داده مصنوعی انجام نشده است. انتخاب این دو دسته، نماینده کل آمازون نیست.

تاریخ دریافت 2026-11-01 است. نشانی رسمی، اندازه و SHA-256 هر فایل در `data/source_manifest.json` ثبت شده است. داده خام بدون ویرایش در بسته قرار دارد. بارگذاری خط‌به‌خط JSONL انجام می‌شود و خطای تجزیه باعث توقف می‌شود؛ تعداد خطای مشاهده‌شده صفر است.

رابطه اجزا: هر نقد با `parent_asin` به یک محصول متصل می‌شود. اتصال از چند نقد به یک ردیف فراداده است؛ اعتبارسنجی `many_to_one` از تکثیر ناخواسته ردیف‌ها جلوگیری می‌کند. `asin` شناسه گونه محصول است و جایگزین کلید والد نمی‌شود. پس از ممیزی، پوشش اتصال در هر دو دسته 100% است.

تعداد محصول‌های والد: 3,391 مجله و 641 بسته. تعداد گونه در نقدهای معتبر به‌ترتیب 3,391 و 1,128 است؛ بنابراین استفاده از گونه در تقسیم، به‌خصوص برای بسته‌ها، خطر اشتراک محصول والد را ایجاد می‌کند.

۳. ساختار، فرهنگ داده و زمان دسترس‌پذیری

فایل نقد دارای ۱۰ فیلد و فراداده بسته دارای ۱۴ و فراداده مجله در مجموع دارای ۱۶ فیلد است. جدول کامل نوع واقعی هر فیلد، شامل تعداد هر نوع، در tables/raw_schema.csv موجود است. نبود کلید، مقدار تهی، رشته خالی، فهرست خالی و فرهنگ خالی جداگانه در raw_missingness.csv شمارش شده‌اند.

فیلد نقد	معنا و تصمیم تحلیلی
rating	عدد از یک تا پنج؛ فقط مرجع هدف، ورودی مدل نیست.
title,text	عنوان و بدنه نقد؛ منبع اصلی تحلیل متن.
images	فهرست نشانی تصویر بارگذاری‌شده در نقد؛ تصویر محصول نیست.
asin,parent_asin	شناسه گونه و محصول والد؛ برای اتصال و تقسیم، بدون ورود مستقیم به مدل.
user_id	شناسه مستعار کاربر؛ برای ممیزی وابستگی، بدون استخراج هویت.
timestamp	عدد صحیح زمان یونیکس در فایل حاضر برحسب میلی‌ثانیه؛ تبدیل به UTC.
helpful_vote	رأی انباشته در زمان گردآوری؛ برای ممیزی، خارج از ورودی پیش‌بینی هنگام ثبت.
verified_purchase	مقدار بولی تأیید خرید؛ زمینه مشاهده، نه گواه کیفیت یا صداقت.

گروه فراداده	تفسیر
title,description,features	عنوان، توضیح و ویژگی‌های محصول در نسخه گردآوری‌شده.
categories,main_category	دسته‌بندی؛ دسته فایل مبدأ نیز مستقل نگهداری می‌شود.
price	قیمت زمان گردآوری طبق فرهنگ رسمی؛ هیچ مقدار عددی قابل استفاده در این دو دسته نیست.
images,videos	فهرست رسانه محصول؛ نشانی، تضمین دسترسی یا سلامت پیکسل نیست.
average_rating,rating_number	تجمیع امتیازها؛ می‌تواند از نقدهای آزمون و آینده تأثیر گرفته باشد، ممنوع برای ورودی اصلی.
store,details,bought_together	فروشگاه، مشخصات و رابطه محصول؛ وضعیت تاریخی آن‌ها معلوم نیست.

واحد مشاهده و پیش‌بینی، نقد است؛ واحد اتصال، محصول والد؛ واحد تقسیم اصلی و بازنمونه‌گیری آینده، محصول است. فراداده، یک عکس لحظه‌ای از کاتالوگ است. بنابراین ادعای اصلی این طرح تعمیم گذشته‌نگر به محصول دیده‌نشده است، نه پیش‌بینی معتبر آینده تقویمی.

۴. ممیزی کیفیت و تصمیم برای هر مسئله

مورد	تعداد	تصمیم
نقد خام	87,713	حفظ نسخه اصلی
نسخه تکراری دقیقِ اضافی	774	حذف کپی پس از ثبت هش
ردیف با کلید کسب‌وکار تکراریِ متفاوت	2	قرنطینه هر دو ردیف
امتیاز خارج از مجموعه مجاز	0	در صورت وقوع قرنطینه
زمان نامعتبر یا خارج بازه مرجع	0	در صورت وقوع قرنطینه
شناسه والد یا گونه نامعتبر	0	ثبت؛ والد نامعتبر قرنطینه
شناسه کاربر خالی	0	در صورت وقوع قرنطینه
رأی منفی، غیرعددی یا غیرصحیح	0	در صورت وقوع تبدیل صریح به تهی
تأیید خرید با نوع نادرست	0	در صورت وقوع حفظ به‌صورت نامعلوم
کلید تکراری فراداده / اتصال ناموفق	0 / 0	توقف اتصال مبهم / نشانگر نبود

تکراری دقیق به معنی یکسانی همه فیلدهای خام پس از مرتب‌سازی کلیدهای JSON است؛ 774 تعداد نسخه اضافی است، نه تعداد گروه‌های تکراری. کلید کسب‌وکار، ترکیب کاربر، والد و زمان است. دو ردیف هم‌کلید که کل محتوایشان یکسان نیست، بدون انتخاب براساس برچسب کنار گذاشته می‌شوند. هش آن‌ها در `data/processed/quarantine.csv` قرار دارد.

پس از این دو تصمیم، 86,937 نقد معتبر داریم. شمار تکرار متن نرمال‌شده با حداقل پنج واژه، 1043 نسخه اضافی است. این مسئله با تکراری دقیق فرق دارد و در جلوگیری از نشت میان بخش‌ها مدیریت می‌شود. 38 جفت کاربر–محصول بیش از یک مشاهده دارند؛ تکرار تعامل به‌خودی‌خود دلیل حذف همه تعامل‌ها نیست.

قیمت: از 4,032 ردیف فراداده، 4,031 مقدار قیمت تهی است و مقدار دیگر رشته خط تیره بلند است. هیچ‌یک به قیمت عددی تبدیل نمی‌شود. جایگزینی با میانگین یا صفر توجیه ندارد. قیمت از ویژگی‌های پیشنهادی حذف شده و نبود آن صریح گزارش می‌شود.

پرت‌ها: در آموزش، آستانه Q3+1.5 IQR طول متن 106.5 واژه و رأی مفیدبودن 7.5 است. به‌ترتیب 4,874 و 6,868 ردیف علامت می‌خورند. این نقاط الزاماً خطا نیستند و حذف نشده‌اند. آستانه فقط روی آموزش محاسبه شده است. برای بررسی طول‌های بسیار بلند، آستانه مستقل از داده برابر ۲۰۰ واژه نیز از پیش تعریف شده است.

۵. ممیزی اجزای چندوجهی و نبود داده

جدول زیر از 86,937 نقد معتبر، قبل از حذف متن‌های مشترک میان بخش‌ها، به دست آمده است. در این صفحه درصدها دسترس‌پذیری ورودی را توصیف می‌کنند و نتیجه مدل نیستند.

وجه در سطح نقد	مجله، 70,922 نقد	بسته، 16,015 نقد
بدنه غیرخالی	99.9986%	99.9313%
عنوان نقد	100%	100%
نشانی تصویر کاربر	0.3102%	9.0103%
اتصال فراداده محصول	100%	100%
نشانی تصویر محصول	100%	100%
قیمت عددی معتبر	0%	0%
زمان / رابطه کاربر–محصول	100 / 100%	100 / 100%

فیلد در سطح محصول	مجله، 3,391 محصول	بسته، 641 محصول
توضیح محصول	45.65%	0%
فهرست ویژگی‌ها	0%	97.04%
سلسله‌مراتب دسته	75.41%	0%
مشخصات ساختاریافته	97.17%	6.40%
نام فروشگاه	94.66%	99.84%

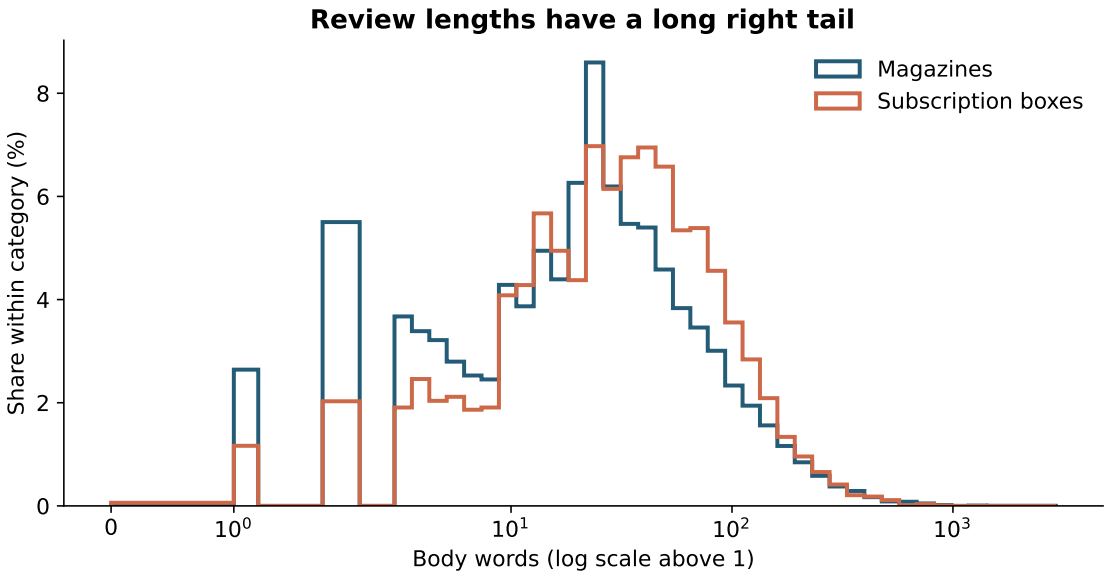
نبود تصویر نقد با دسته مرتبط است؛ اندازه توصیفی رابطه Cramer’s V برابر 0.246 است. نبود توضیح، ویژگی‌ها و سلسله‌مراتب نیز تفاوت نظام‌مند دارد؛ برای ویژگی‌ها $V=0.982$ است. این اثرها دلیل رد برداشت ساده «نبود کاملاً تصادفی» هستند، اما سازوکار MAR/MNAR را اثبات نمی‌کنند. برای قیمت و تصویر محصول، تغییرپذیری نداریم و آزمون رابطه معنی ندارد.

نبود تصویر کاربر با نبود تصویر محصول یکی نیست. نشانی تصویر محصول برای همه کالاها موجود است، ولی بایت تصویر دریافت یا صحت‌سنجی نشده است. ترکیب متن و فراداده در فازهای بعد باید با مقایسه وجه‌های مستقل و حذف هر وجه ارزیابی شود؛ چسباندن ستون‌ها یا این ممیزی به‌تنهایی اثبات سودمندی چندوجهی نیست.

۶. توزیع طول و کیفیت متن

واژه در این گزارش، واحد جداشده با فاصله پس از نرمال‌سازی NFKC، بازکردن موجودیت‌های HTML، حذف برچسب‌ها و یکسان‌سازی فاصله‌ها است؛ این شمارش، توکن مدل زبانی نیست. طول عنوان برای ممیزی کپی با بدنه ترکیب می‌شود، ولی توزیع طول این صفحه فقط بدنه را می‌سنجد.

دسته آموزش	میانه	میانگین	انحراف معیار	صدک ۹۵	بیشینه
مجله، واژه	22	39.03	62.14	137	2,921
بسته، واژه	30	46.81	56.31	144	865
مجله، نویسه	119	218.69	355.60	771	16,898
بسته، نویسه	158	248.93	301.89	771.8	4,535



شکل 1: توزیع طول بدنه در بخش آموزش؛ محور طول بالاتر از یک، لگاریتمی است.

میانه کلی 23 واژه است. 6,316 نقد، یعنی 10.53%، حداکثر سه واژه و 1,398 نقد، یعنی 2.33%، دست‌کم ۲۰۰ واژه دارند. بدنه 8 نقد آموزش خالی است. برای این موارد، عنوان در شاخه متن آینده قابل استفاده است؛ نبود بدنه نیز باید علامت‌گذاری شود.

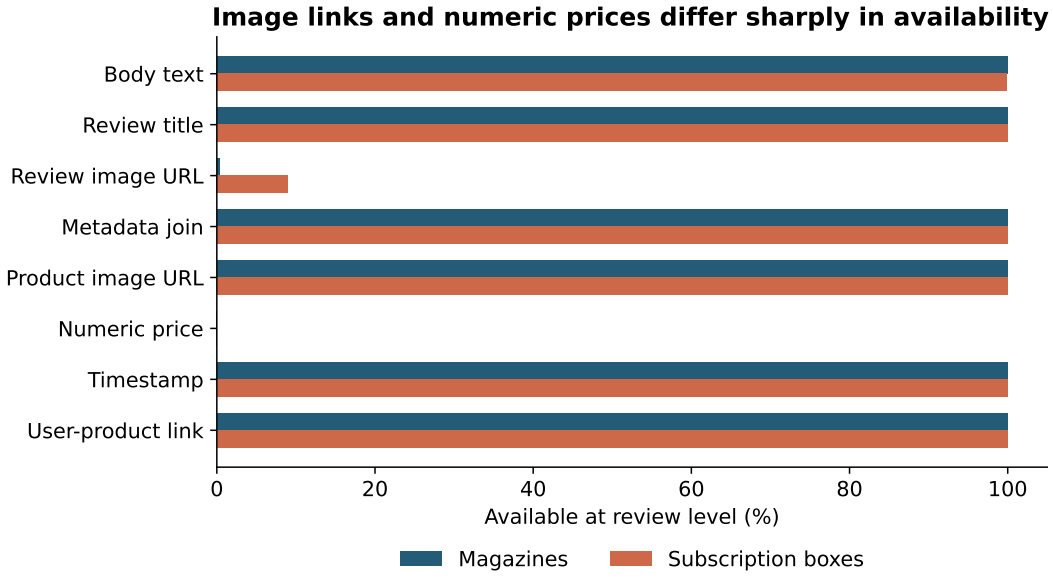
میانگین بزرگ‌تر از میانه و بیشینه‌های بزرگ، دنباله راست بلند را نشان می‌دهد. طول متن در مهندسی ویژگی آینده با log(1+length) و شاخص نبود مدیریت می‌شود؛ در این فاز متن بلند به دلیل طول حذف نشده است.

۷. نویسه‌ها، زبان و الگوهای ثبت متن

شاخص در بخش آموزش	مجله، 48,378	بسته، 11,585
بدنه حداکثر سه واژه	11.82%	5.16%
بدنه حداقل ۲۰۰ واژه	2.32%	2.37%
وجود نویسه غیر ASCII	3.70%	20.75%
وجود برچسب یا موجودیت HTML	12.32%	11.21%
نویسه جایگزین U+FFFD	0	0
نویسه کنترلی غیر از خط جدید/تب	11	0
وجود نویسه محدوده عربی / چینی	0 / 0	0 / 0

تفاوت غیر ASCII به‌تنهایی نشانه غیرانگلیسی‌بودن نیست؛ ایموجی، آپاستروف خمیده و نشانه‌گذاری معمول هم غیر ASCII هستند. این گزارش، تشخیص زبان خودکار ادعا نمی‌کند. پرچم‌های محدوده نویسه و سهم حروف لاتین، غربال اولیه‌اند. زبان‌هایی با الفبای لاتین و کنایه یا متن ترکیبی با این روش به‌طور قطعی تفکیک نمی‌شوند.

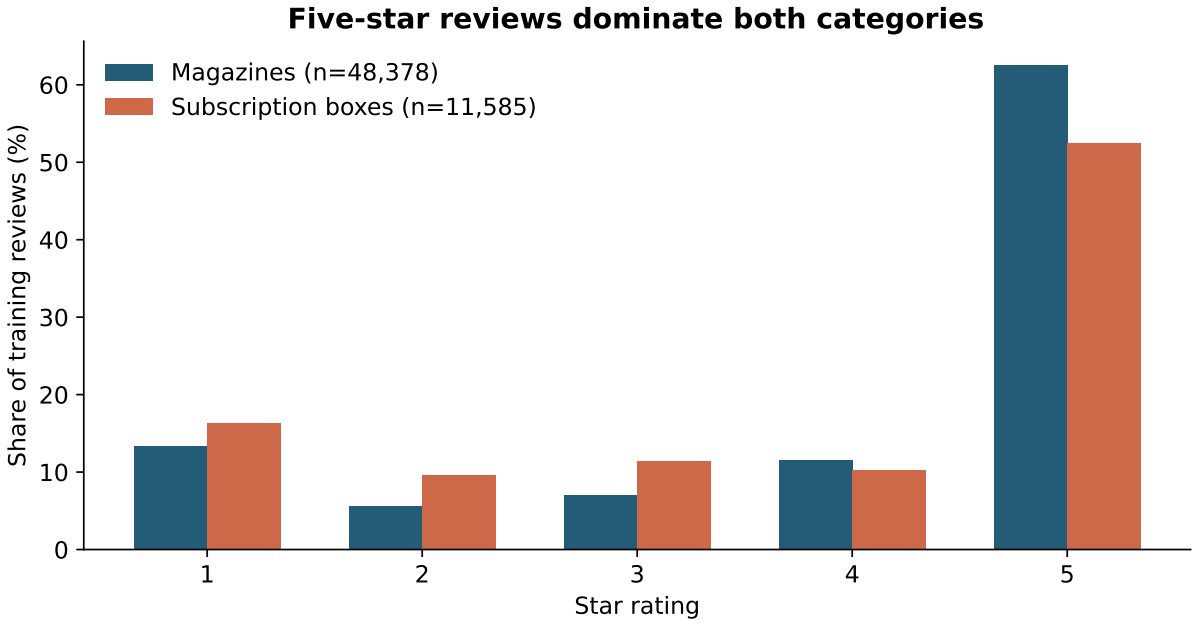
هیچ ردیف فقط به‌دلیل غیر ASCII بودن حذف نشده است. برچسب‌های HTML در متن مشتق‌شده باز می‌شوند؛ داده اصلی حفظ شده است. نویسه کنترلی باید پیش از مدل‌سازی بررسی و طبق قاعده مستند پاک‌سازی شود، نه اینکه کورکورانه همه متن را به ASCII تبدیل کنیم.



شکل 2: دسترس‌پذیری وجه‌ها در سطح نقد؛ وجود نشانی تصویر با دریافت پیکسل یکسان نیست.

۸. توزیع امتیاز و عدم توازن

در 59,963 نقد آموزش، 12,194 نقد دارای یک یا دو ستاره است؛ فراوانی هدف 20.34% است. نسبت امتیاز پایین در مجله حدود 19.01% و در بسته حدود 25.88% است. بنابراین دسته‌ها هم از نظر اندازه و هم از نظر نرخ هدف یکسان نیستند.



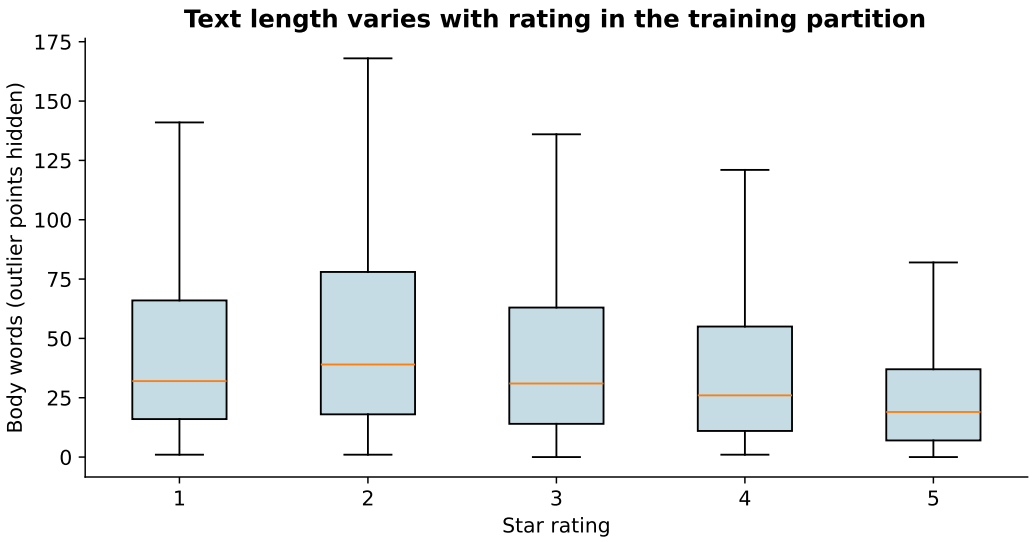
شکل 3: توزیع امتیاز در آموزش با مخرج مستقل برای هر دسته؛ بخش آزمون در این شکل دخالت ندارد.

غلبه پنج‌ستاره‌ها سبب می‌شود دقت به‌تنهایی معیار مناسبی نباشد. قاعده همیشگی «غیرمنفی» روی آموزش دقت 79.66% می‌گیرد ولی بازیابی نقد منفی آن صفر است. این مقدار، ارزیابی مدل روی داده نگه‌داشته‌شده نیست.

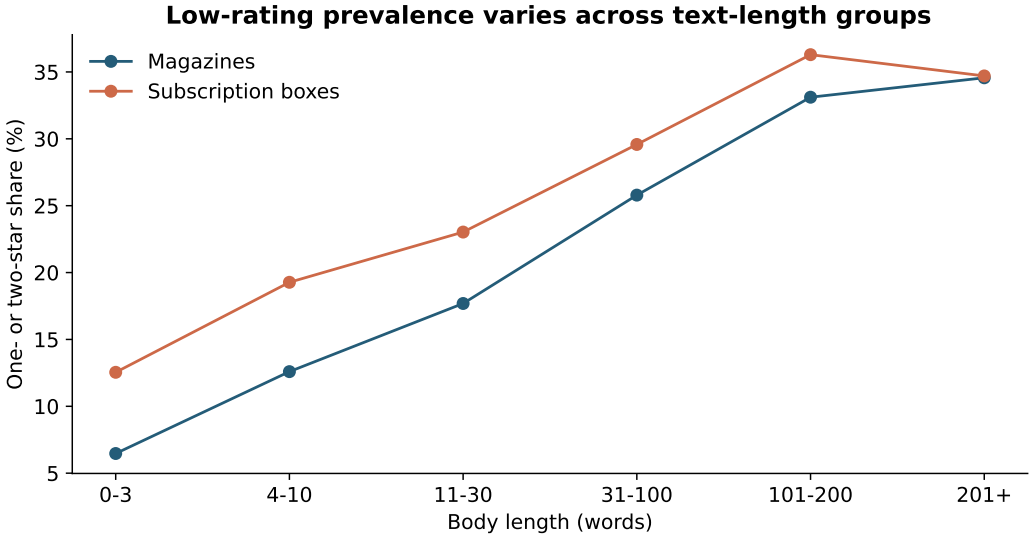
تفاوت امتیاز ممکن است با ترکیب محصول، دوره زمانی، نوع خرید یا انتخاب کاربران برای نوشتن نقد مرتبط باشد. از تفاوت دسته نمی‌توان نتیجه گرفت که یک دسته ذاتاً باکیفیت‌تر است. میانگین امتیاز آموزش مجله 4.04 و بسته 3.73 است؛ توزیع کامل و عدم توازن در تفسیر این میانگین‌ها اهمیت دارد.

برای فاز مدل‌سازی، معیار اصلی Average Precision با تعریف میانگین دقت در نقاط بازیابی است. Macro-F1، بازیابی و دقت کلاس منفی، دقت متوازن و کالیبراسیون معیارهای مکمل‌اند. انتخاب آستانه صرفاً با اعتبارسنجی انجام خواهد شد.

۹. رابطه طول متن و امتیاز



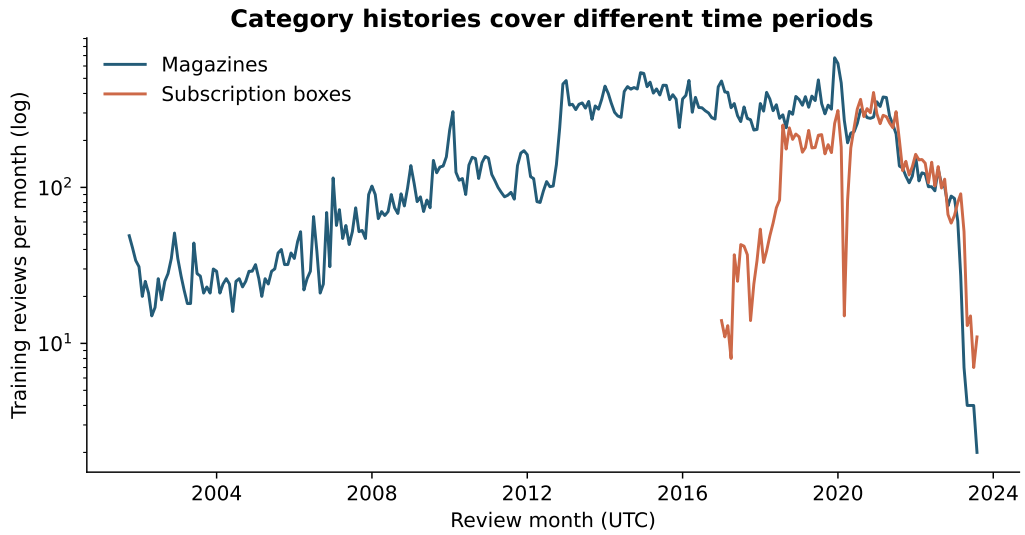
شکل 4: طول متن به تفکیک ستاره در آموزش؛ نقاط پرت برای خوانایی نمودار نمایش داده نشده‌اند، اما از داده حذف نشده‌اند.



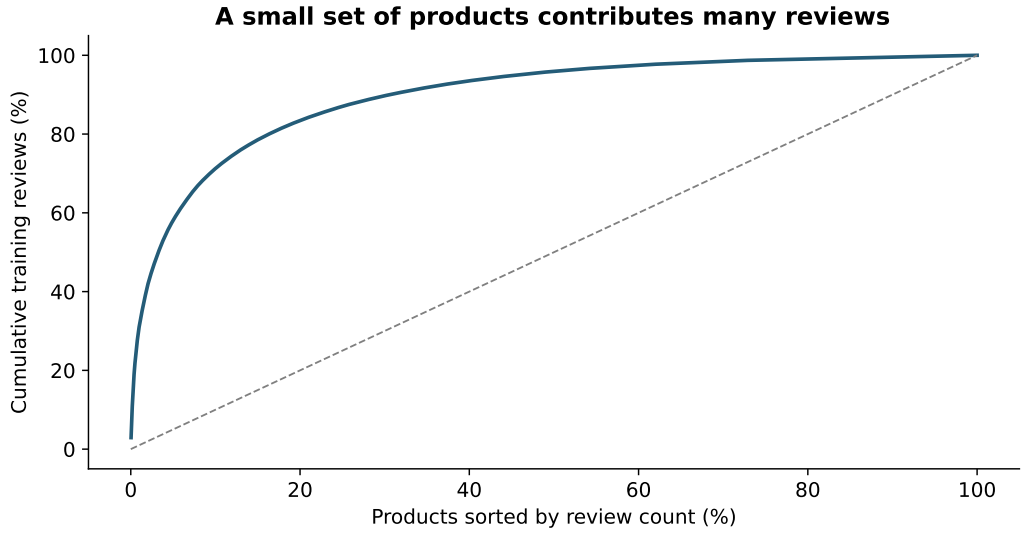
شکل 5: نرخ یک/دوستاره در طبقه‌های طول؛ اعداد مخرج هر گروه در جدول همراه ارائه شده‌اند.

همبستگی رتبه‌ای طول و امتیاز در کل آموزش -0.235 است؛ در مجله -0.235 و در بسته -0.188 است. در نقدهای مجله، نرخ هدف از حدود 6.47% در گروه صفر تا سه واژه به 34.56% در گروه بیش از ۲۰۰ واژه می‌رسد. این رابطه توصیفی است؛ طولانی‌ترکردن متن علت نارضایتی نیست و طبقه‌های انتهایی نمونه کمتری دارند.

۱۰. زمان، تعامل و تمرکز کالاها



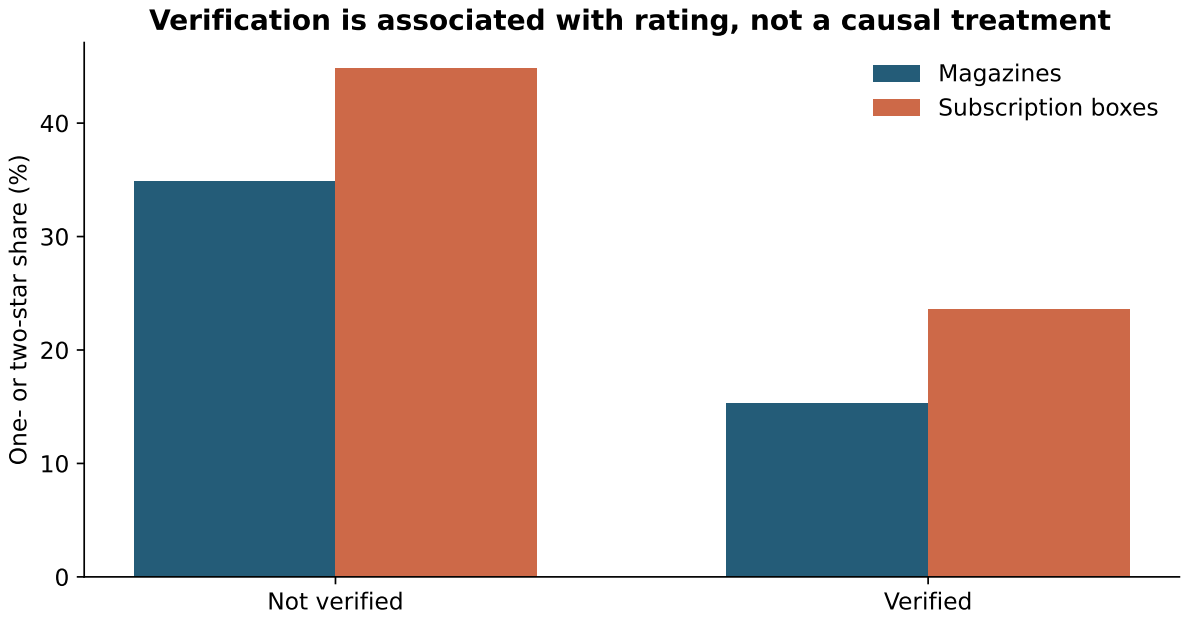
شکل 6: فعالیت ماهانه آموزش در مقیاس لگاریتمی؛ بازه تاریخی دسته‌ها متفاوت است و تعداد نقد، تقاضا یا فروش نیست.



شکل 7: سهم تجمعی نقدها با مرتب‌سازی کالاها از پرنقد به کم‌نقد.

ده محصول پرنقد، 17.74% نقدهای آموزش را تولید می‌کنند. پس تعداد زیاد ردیف لزوماً تعداد زیادی مشاهده مستقل نیست. وابستگی درون محصول، دلیل انتخاب تقسیم برحسب والد و بازنمونه‌گیری خوشه‌ای در فاز ارزیابی است. دوره تاریخی مجله بسیار بلندتر است؛ مقایسه خام دسته‌ها می‌تواند با زمان مخدوش شود. این نمودار مبنای ادعای روند فروش یا اثر فصل نیست.

۱۱. زیرگروه‌ها و چند رابطه مکمل



شکل 8: رابطه وضعیت تأیید خرید و نرخ هدف در آموزش؛ وضعیت تأیید خرید تخصیص تصادفی ندارد.

در مجله، نرخ یک/دوستاره برای خرید تأییدنشده 34.86% و برای تأییدشده 15.26% است. در بسته، این دو مقدار 44.86% و 23.55% هستند. اندازه گروه‌ها در جدول `train_negative_by_verified.csv` ثبت شده است. این اختلاف، رابطه مشاهده‌ای است و اثر علّی تأیید خرید یا شاهد صداقت نقد نیست.

در نقدهای دارای تصویر کاربر، نرخ هدف مجله 27.45% در 153 ردیف و بسته 24.34% در 986 ردیف است. گروه مجله بسیار کوچک است؛ نتیجه آن نباید به همه کاربران تعمیم داده شود. در نقدهای بدون تصویر، این نرخ‌ها به‌ترتیب 18.98% و 26.02% است.

همبستگی رتبه‌ای طول متن با رأی مفیدبودن در کل آموزش 0.479، در مجله 0.488 و در بسته 0.364 است. این رابطه می‌تواند با سن نقد، دیده‌شدن، محبوبیت کالا و کیفیت متن مرتبط باشد. چون رأی‌ها در یک بازه پیگیری یکسان شمارش نشده‌اند، از آن نتیجه نمی‌گیریم که افزایش طول، رأی بیشتر ایجاد می‌کند.

هیچ آزمون معنی‌داری با فرض استقلال همه ردیف‌ها برای این مقایسه‌ها گزارش نشده است. اندازه اثر و مخرج‌ها توصیفی‌اند. برای فاز بعد، گزارش خطا برحسب دسته، طول و تأیید خرید و فاصله عدم قطعیت با بازنمونه‌گیری محصول لازم است.

۱۲. طراحی تقسیم و خطرهای نشت اطلاعات

تقسیم اصلی، برحسب محصول والد و مستقل از برچسب است. برای هر والد، ۱۶ رقم اول SHA-256 رشته `parent_asin:401100025` به عددی در بازه صفر تا یک تبدیل می‌شود. بازه کمتر از 0.70 آموزش، از 0.70 تا کمتر از 0.85 اعتبارسنجی و بقیه آزمون است. نسبت‌ها احتمال تخصیص محصول‌اند؛ سهم ردیف‌ها الزاماً دقیقاً ۷۰/۱۵/۱۵ نیست.

متن عنوان و بدنه نرمال می‌شود. اگر رشته یکسانِ دارای حداقل پنج واژه میان بخش‌ها تکرار شود، ردیف بخش با اولویت پایین‌تر حذف می‌شود: آموزش مقدم بر اعتبارسنجی و اعتبارسنجی مقدم بر آزمون. این تصمیم به امتیاز نگاه نمی‌کند. 393 ردیف کنار گذاشته شده و علت هر مورد در فایل عضویت آمده است.

بخش نهایی	نقد	محصول والد	نقش
آموزش	59,963	2,842	تحلیل و برازش آینده
اعتبارسنجی	10,912	563	انتخاب تنظیمات آینده
آزمون	15,669	612	ارزیابی نهایی آینده

اشتراک محصول و متن‌های یکسان مشمول قاعده، بین هر دو بخش صفر است. کاربر مشترک آموزش/اعتبارسنجی 1,459، آموزش/آزمون 2,641 و اعتبارسنجی/آزمون 581 است. این طرح «کالای جدید» را هدف می‌گیرد؛ «کاربر جدید» یا «آینده زمانی» نیست. شناسه کاربر و تجمیع برچسب کاربر وارد مدل نمی‌شود. متن تقریباً مشابه و عبارت‌های بسیار کوتاه همچنان محدودیت‌اند.

منابع نشت و کنترل: ستاره و میانگین/تعداد امتیاز محصول از ورودی حذف می‌شوند. رأی انباشته هنگام ثبت قابل مشاهده نیست. قیمت و شرح ویرایش‌شده زمان تاریخی معلوم ندارند. واژگان، TF-IDF، جایگذاری و مقیاس‌گذاری فقط از آموزش یاد گرفته می‌شوند. انتخاب آستانه با اعتبارسنجی است و آزمون برای تنظیم استفاده نمی‌شود. تمام تحلیل‌های امتیاز، متن و زیرگروه در این گزارش روی آموزش است؛ ممیزی تمام داده به ساختار، تمامیت، بازه زمان و وجود ورودی محدود شده است.

۱۳. خط مبنا و طرح ادامه پروژه

خط مبنای نخست، پیش‌بینی همیشگی کلاس پرتکرار است. خط مبنای امتیازی، احتمال ثابت برابر سهم منفی آموزش است. این دو خط مبنا شفاف‌اند و نشان می‌دهند امتیاز بالای دقت می‌تواند بدون یافتن حتی یک نقد منفی حاصل شود.

مرجع توصیفی آموزش	مقدار
سهم منفی / امتیاز احتمال ثابت	20.34%
دقت قاعده اکثریت	79.66%
بازیابی کلاس منفی قاعده اکثریت	0
امتیاز ثابت روی آموزش AP	0.2034
احتمال ثابت روی آموزش Brier	0.1620
احتمال ثابت روی آموزش Log loss	0.5050

اعداد این جدول عملکرد اعتبارسنجی یا آزمون نیستند. در فاز سوم، خط مبنای متن شامل TF-IDF + Logistic Regression، شاخه ساختاری شامل تأیید خرید، دسته و ویژگی‌های معتبر کاتالوگ، و ترکیب آن‌ها روی همان ردیف‌ها مقایسه خواهد شد. قیمت و تجمیع امتیاز ممنوع‌اند. شاخص نبود برای فیلدهای نامتوازن ضروری است؛ بهبود صرفاً ناشی از یادگیری نام دسته کافی نیست.

برای کشف الگو در فاز دوم، TF-IDF آموزش با TruncatedSVD کاهش می‌یابد و K-means با تعداد خوشه 3,5,8 بررسی می‌شود. انتخاب با سیلوئت روی نمونه ثابت آموزش، پایداری در بذرها/زیرنمونه‌ها و تفسیر واژه‌ها انجام می‌شود. امتیازها برای آموزش خوشه‌ها به کار نمی‌روند. این روش‌ها برنامه‌اند و در فاز اول اجرا نشده‌اند.

معیار اصلی آینده AP و معیارهای مکمل شامل Macro-F1، بازیابی/دقت منفی، دقت متوازن و Brier است. در فاز نهایی حذف وجه متن یا ساختار، تحلیل حساسیت حذف سه‌ستاره‌ها، بررسی انتقال دسته و بازنمونه‌گیری هزارباره برحسب محصول تعریف می‌شود. اگر تصویر استفاده شود، باید ابتدا بایت‌ها دریافت و اعتبارسنجی شوند و مدل ازپیش‌آموزش‌دیده و نسخه آن ثبت شود. این گزارش ادعای کسب امتیاز اضافه چندوجهی ندارد.

۱۴. اخلاق، حریم خصوصی و محدودیت‌ها

شناسه کاربران مستعار است؛ تلاش برای یافتن هویت واقعی مجاز نیست. خروجی مشتق‌شده به‌جای شناسه خام، هش نمک‌دار دارد. این کار نام مستعار ایجاد می‌کند و ناشناس‌سازی قطعی نیست. متن خام ممکن است اطلاعات شخصی داشته باشد؛ در گزارش نقد کامل فردی نقل نشده است.

فایل خام برای بازاجرا در بسته خصوصی قرار دارد ولی در Git دنبال نمی‌شود. دسترسی عمومی به داده به‌معنی مجوز نامحدود بازنشر نیست. کارت داده بررسی‌شده مجوز جامع روشنی ارائه نمی‌کند؛ پیش از بازنشر عمومی، شرایط منبع و حقوق متن/تصویر باید بررسی شود. انتساب منبع، نشانی دریافت و هش‌ها حفظ شده‌اند.

- جمعیت هدف محدود به نقدهای منتشرشده همین دو دسته است؛ سکوت مشتریان و نقد حذف‌شده دیده نمی‌شود.
- امتیاز پایین، برچسب ضعیف نارضایتی است. شکایت درباره تحویل، محتوا یا قیمت لزوماً کیفیت محصول را نمی‌سنجد.
- قیمت قابل استفاده نداریم. نبود فیلدهای کاتالوگ شدیداً با دسته مرتبط است و می‌تواند میان‌بُر ایجاد کند.
- نشانی تصویر، داده پیکسلی تأییدشده نیست. کیفیت، دسترس‌پذیری شبکه و محتوای تصویر ممیزی نشده است.
- فراداده لحظه گردآوری، موجودبودن همان ویژگی در زمان هر نقد را ثابت نمی‌کند؛ تعمیم زمانی ادعا نشده است.
- هم‌پوشانی کاربر و متن‌های تقریباً مشابه باقی می‌ماند؛ تنها تکرار دقیق مشمول قاعده کنترل شده است.
- هیچ اختلاف مشاهده‌ای، اثر علّی خرید تأییدشده، طول متن یا دسته محصول را اثبات نمی‌کند.

کاربرد مجاز پیشنهادی، کمک به بررسی انسانی است. مدل آینده نباید خودکار شکایت را رد کند، مشتری را متقلب بنامد یا حق بازپرداخت تعیین کند. پیش از استفاده واقعی، هزینه خطا، بررسی زیرگروه‌ها، کالیبراسیون و داده به‌روز لازم است.

از ChatGPT/Codex برای طراحی، کدنویسی، اجرای ممیزی و نگارش کمک گسترده گرفته شده است. جزئیات در `AI_USAGE.md` ثبت شده؛ هیچ نقد یا نتیجه تجربی با هوش مصنوعی جعل نشده است. دانشجو باید محاسبات و تصمیم‌ها را مستقلاً مرور کند و توان دفاع از آن‌ها را داشته باشد.

۱۵. بازتولید، اقلام تحویل و منابع

محیط تحلیلی ثبت‌شده: Python 3.11 یا جدیدتر سازگار با نسخه‌های قفل‌شده، NumPy 2.3.5، pandas 2.2.3، Matplotlib 3.10.8 و SciPy 1.17.0. نسخه دقیق اجرا در `audit_summary.json` آمده است. برای ساخت PDF از XeLaTeX و فونت همراه استفاده شده است.

از پوشه اصلی پروژه، با نصب وابستگی‌ها، دستور `pythonreproduce.py` تمام هش‌ها را بررسی می‌کند، ممیزی و شکل‌ها را می‌سازد، دفترچه را اجرا می‌کند، آزمون‌ها را اجرا و دو PDF را کامپایل می‌کند. اگر داده خام موجود باشد، اجرا به اینترنت نیاز ندارد. راهنمای اجرای Windows و ساخت مستقیم لاتک در `README.md` است.

مسیر	محتوا
`PROJECT_CARD.md`	همه چهارده بند کارت پروژه و سه سؤال اولیه
`src/,configs/,tests/`	بارگذاری، ممیزی، تقسیم، ساخت مستندات و آزمون تمامیت
`notebooks/phase1_audit.ipynb`	دفترچه اجراشده با خروجی واقعی و شکل‌ها
`data/,tables/,figures/`	چهار ورودی، عضویت تقسیم، خروجی مشتق، جداول و شکل‌های برداری
`reports/phase1.pdf,phase1.tex`	گزارش حاضر و منبع لاتک
`reports/presentation.pdf`	اسلاید ارائه همراه با منبع لاتک
`AI_USAGE.md,docs/`	افشای هوش مصنوعی، چک‌لیست الزامات و راهنمای دفاع
`sources/,fonts/,texmf/`	صورت پروژه، ارجاعات، فونت و بسته‌های همراه لاتک

بسته Git همراه، برچسب محلی `phase-1` را دارد. مخزن راه‌دور ساخته یا بارگذاری نشده است. ثبت موضوع و ارسال به GitHub/CW با حساب دانشجو و طبق اطلاعیه رسمی درس انجام می‌شود. ویدیوی ضبط‌شده و دفاع شفاهی، الزام تحویل نهایی کل پروژه‌اند و به‌عنوان خروجی انجام‌شده فاز اول معرفی نشده‌اند.

مراجع

[1] McAuley Lab. Amazon Reviews’23. Official dataset, data fields and download links. Accessed 2026-11-01. https://amazon-reviews-2023.github.io/

[2] Hou, Y., Li, J., He, Z., Yan, A., Chen, X., and McAuley, J. (2024). Bridging Language and Items for Retrieval and Recommendation. arXiv:2403.03952. https://arxiv.org/abs/2403.03952

[3] تیم دستیاران درس تحلیل داده. صورت پروژه پاییز ۱۴۰۵، صفحات ۵ تا ۷ و ۱۷ تا ۱۸؛ نسخه همراه در `sources/project_description.pdf`.