شناسایی نارضایتی متنی

در نقدهای خدمات اشتراکی

فاز اول پروژه تحلیل داده، مسیر ب
Amazon Reviews’23

محمدرضا استادعظیم
شماره دانشجویی: 401100025

پاییز ۱۴۰۵، دانشکده علوم ریاضی

مسئله و سؤال اصلی

صف بررسی انسانی برای متن بازخورد، وقتی ستاره در دسترس نیست.

- مرجع ضعیف نارضایتی: امتیاز یک یا دو ستاره، با حذف ستاره از ورودی.
- سؤال: آیا متن همراه زمینه و فراداده، در محصول دیده‌نشده بهتر از متن تنها عمل می‌کند؟
- فاز اول: شناخت داده و امکان‌پذیری؛ هنوز مدل پیش‌بینی آموزش نداده‌ایم.

اگر ستاره معتبر در کاربرد موجود باشد، استفاده مستقیم از آن منطقی‌تر است. سؤال‌ها و دامنه: PROJECT_CARD.md.

داده و زیرمجموعه

دسته رسمی	نقد خام	محصول
اشتراک مجله	71,497	3,391
بسته اشتراکی	16,216	641

- تمام رکوردهای این دو دسته، بدون نمونه‌گیری براساس امتیاز.
- نقدهای منتشرشده و کاتالوگ مشاهده‌ای، از ۲۰۰۱ تا ۲۰۲۳.
- اتصال نقد به محصول با parent_asin، با پوشش 100%.

منبع رسمی: amazon-reviews-2023.github.io؛ نشانی و هش چهار فایل: data/source_manifest.json.

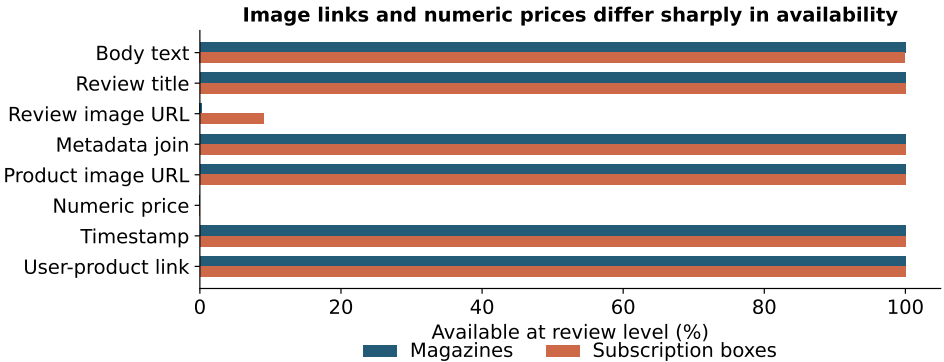
کیفیت داده و تصمیم‌ها

نقد خام	87,713
نسخه تکراری دقیق اضافی	774
ردیف هم‌کلیدِ متفاوت، قرنطینه	2
نقد معتبر پیش از تقسیم	86,937
قیمت عددی معتبر	0، از 4,032 محصول

امتیاز نامعتبر، زمان نامعتبر و اتصال ناموفق مشاهده نشد.

داده خام حفظ شده است. قیمت تهی را با صفر یا میانگین پر نکرده‌ایم. جزئیات: tables/quality_issues.csv.

دسترس‌پذیری وجه‌ها



تصویر نقد: مجله 0.31%، بسته 9.01%. قیمت عددی در هیچ دسته موجود نیست.

ممیزی کل داده معتبر، با مخرج نقد. تصویر یعنی وجود نشانی، نه دریافت و صحت پیکسل.

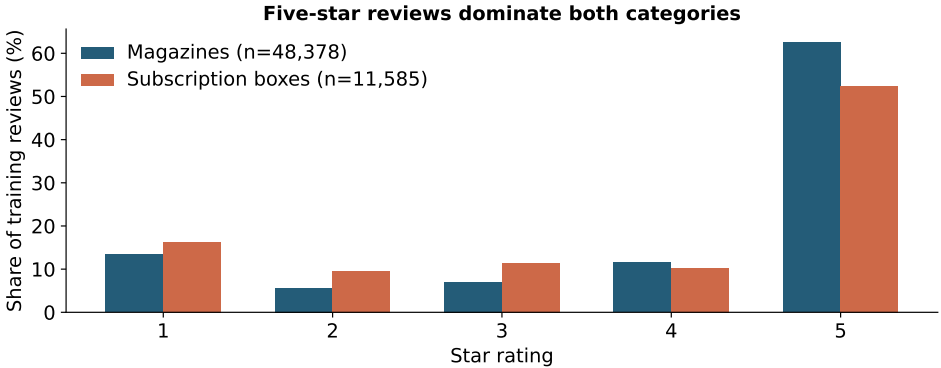
نبود فراداده با دسته مرتبط است

فیلد موجود در سطح محصول	مجله	بسته
توضیح محصول	45.65%	0%
فهرست ویژگی‌ها	0%	97.04%
سلسله‌مراتب دسته	75.41%	0%
مشخصات ساختاریافته	97.17%	6.40%

شاخص نبود می‌تواند نام دسته را افشا کند. مقایسه وجه‌ها باید درون دسته نیز گزارش شود.

مخرج: ۳۳۹۱ محصول مجله و ۶۴۱ محصول بسته. این الگو، سازوکار دقیق نبود داده را اثبات نمی‌کند.

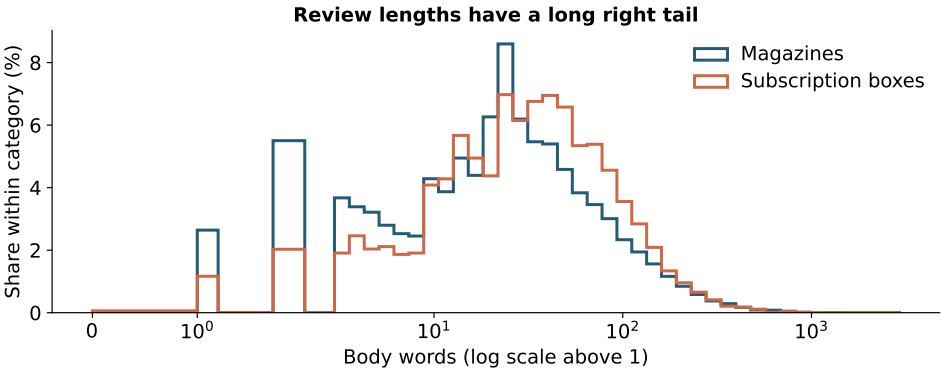
عدم توازن امتیازها



سهم یک/دوستاره در آموزش: 20.34%. دقت اکثریت: 79.66%، بازیابی منفی: صفر.

فقط آموزش؛ این اعداد نتیجه ارزیابی نگه‌داشته‌شده نیستند. معیار اصلی پیشنهادی آینده: Average Precision.

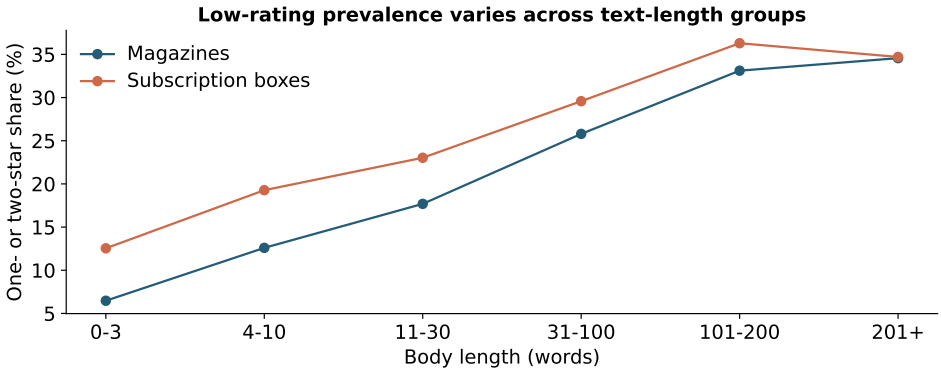
طول نقد و کیفیت متن



میانه 23 واژه؛ 10.53% حداکثر سه واژه؛ 2.33% حداقل ۲۰۰ واژه.

تعریف واژه: جداسازی با فاصله پس از پاک‌سازی HTML. غیر ASCII بودن، تشخیص زبان نیست. همه آمارها از آموزش‌اند.

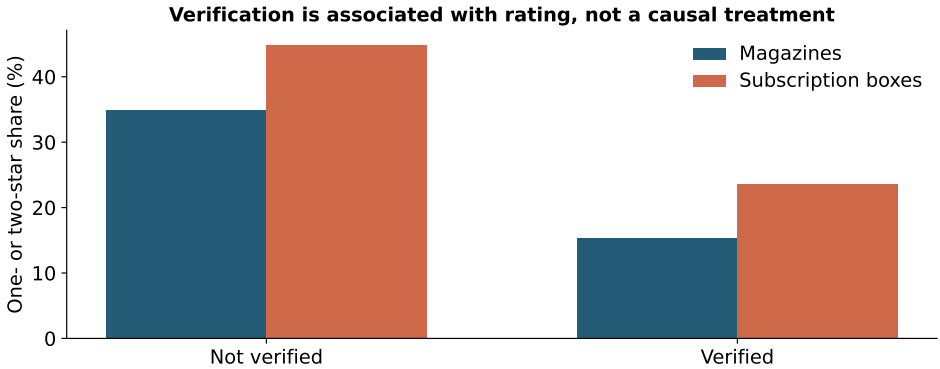
نارضایتی و طول متن



در مجله، سهم یک/دوستاره: متن کوتاه 6.47% و متن بلند 34.56%.

رابطه توصیفی، بدون ادعای علّی. شمار نمونه گروه‌ها در tables/train_negative_by_length.csv آمده است.

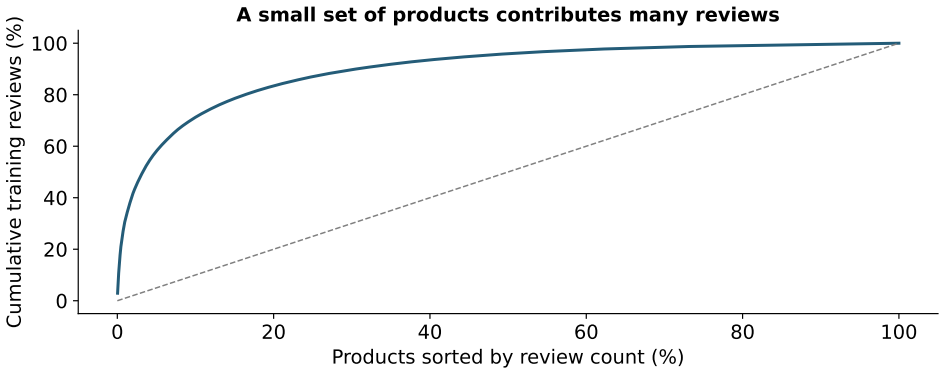
زیرگروه خرید تأییدشده



در هر دو دسته، گروه خرید تأییدشده نرخ امتیاز پایین کمتری دارد.

تأیید خرید تصادفی نیست؛ از این اختلاف نمی‌توان اثر علّی یا صداقت نقد را استنتاج کرد. فقط آموزش.

زمان و وابستگی محصول



ده محصول: 17.74% نقدهای آموزش. وابستگی درون کالا مهم است.

تاریخچه دسته‌ها متفاوت است. تعداد نقد، فروش یا تقاضا نیست. نمودار زمان در گزارش و figures/05_monthly_activity.pdf است.

تقسیم برحسب محصول والد

بخش	نقد نهایی	محصول
آموزش	59,963	2,842
اعتبارسنجی	10,912	563
آزمون	15,669	612

393 متن مشترک مشمول قاعده، از بخش کم‌اولویت حذف شد. اشتراک محصول و متن مشمول قاعده اکنون صفر است.

تقسیم ثابت با SHA-256 و بذر 401100025. کاربر مشترک و متن تقریباً مشابه ممکن است بماند. هدف، کالای جدید است؛ نه کاربر یا زمان جدید.

خط مبنا و کنترل نشت

- مرجع ثابت آموزش: احتمال منفی 20.34% و AP=0.2034.
- ستاره، میانگین/تعداد امتیاز محصول و رأی انباشته از ورودی آینده حذف می‌شوند.
- واژگان و تبدیل‌ها فقط روی آموزش برازش می‌شوند؛ آستانه با اعتبارسنجی انتخاب می‌شود.
- مقایسه آینده: متن تنها، ساختار تنها، ترکیب، روی ردیف‌های یکسان.

هیچ مدل، خوشه یا تعبیه‌ای در فاز اول آموزش داده نشده است. مرجع ثابت، عملکرد آزمون نیست.

محدودیت و نتیجه فاز اول

- متن و نشانی تصویر محصول پوشش بالایی دارند؛ قیمت قابل استفاده نداریم.
- نبود فیلدها با دسته مرتبط است و وابستگی درون محصول جدی است.
- برچسب ستاره ضعیف و کاتالوگ گذشته‌نگر است؛ ادعای تعمیم زمانی نداریم.
- خروجی: ممیزی بازاجراپذیر، تقسیم ثابت، کارت پروژه و برنامه ارزیابی.

هوش مصنوعی در طراحی، کد و نگارش کمک گسترده داشته است؛ افشا در AI_USAGE.md. مرور مستقل و دفاع دانشجو لازم است.

منابع و اجرای دوباره

- صفحه رسمی داده و فرهنگ فیلدها: amazon-reviews-2023.github.io
- Hou et al. (2024), arXiv:2403.03952
- صورت پروژه درس، صفحات ۵ تا ۷ و ۱۷ تا ۱۸.
- اجرای کامل از پوشه اصلی: `python reproduce.py`

بسته شامل داده خام، کد، دفترچه اجراشده، شکل‌ها، جداول، گزارش و منبع لاتک هر دو PDF است.

برچسب phase-1 در بسته Git محلی موجود است. ثبت موضوع و ارسال به GitHub/CW با حساب دانشجو انجام می‌شود.