پروژه درس تحلیل داده، پاییز ۱۴۰۵

From Raw Data to Reliable, Reproducible, and Responsible Data Products

تهیه‌شده توسط تیم دستیاری درس

معرفی درس. درس تحلیل داده ماهیتی ترکیبی دارد و محور اصلی آن مفاهیم داده‌کاوی، یادگیری ماشین و تحلیل داده است. در این درس فرض می‌شود دانشجو پیش از ورود به پروژه با مبانی آمار، رگرسیون و برنامه‌نویسی پایتون آشناست. پروژه‌ی ترم طوری طراحی شده است که بخش قابل توجهی از مباحث اصلی درس در یک مسئله‌ی واقعی و در قالب یک زنجیره‌ی تحلیل داده‌ی کامل تمرین شود.
سایت درس. سایت رسمی درس در حال آماده‌سازی است. نشانی نهایی سایت، فایل‌های آغازین، لینک مجموعه‌داده‌ها، اطلاعیه‌های مربوط به فازها و هرگونه به‌روزرسانی اجرایی از طریق کانال‌های رسمی درس و سامانه‌ی CW اعلام خواهد شد. تا زمان اعلام نشانی نهایی، هیچ لینک غیررسمی به‌عنوان مرجع درس در نظر گرفته نمی‌شود.

۰. سرفصل‌های درس و نسبت آن‌ها با پروژه

بخش‌های پایه‌ی درس که انتظار می‌رود تقریباً در همه‌ی مسیرهای پروژه دیده شوند، عبارت‌اند از:

۱. Problem Understanding and Strategic Thinking with Data؛ فهم مسئله، تعریف هدف و تبدیل یک نیاز واقعی به سؤال قابل تحلیل؛

۲. Data Understanding, Collection, and Quality Assessment؛ شناخت داده، منشأ داده و ارزیابی کیفیت؛

۳. Exploratory Data Analysis (EDA)؛ تحلیل اکتشافی و مصورسازی؛

۴. Data Preparation and Feature Engineering؛ پاک‌سازی، آماده‌سازی و مهندسی ویژگی؛

۵. Pattern Discovery and Unsupervised Learning؛ کشف الگو و یادگیری بدون‌ناظر؛

۶. Clustering and Dimensionality Reduction؛ خوشه‌بندی و کاهش بُعد؛

۷. Predictive Modeling for Regression Problems؛ مدل‌سازی پیش‌بینانه برای مسائل رگرسیون؛

۸. Classification and Data-Driven Decision Making؛ طبقه‌بندی و تصمیم‌گیری مبتنی بر داده؛

۹. Model Evaluation and Experimental Design؛ ارزیابی مدل و طراحی آزمایش؛

۱۰. Correlation, Causality, and Decision Making؛ تمایز همبستگی و علیت و نحوه‌ی استفاده از نتایج برای تصمیم‌گیری.

بخش‌های توسعه‌یافته‌ی درس بسته به مسیر انتخابی و سؤال پروژه وارد تحلیل خواهند شد:

- Model Interpretability and Insight Extraction؛
- Time-Series, Event, and Anomaly Analysis؛
- Unstructured Data Analysis: Text, Audio, and Multimodal Data؛
- AI and Large Language Models for Data Analysis؛
- Data Privacy, Anonymization, Ethics, and Governance؛
- Real-World Industry Case Studies and Data Challenges.

این پروژه قرار نیست همه‌ی دانشجویان را مجبور کند همه‌ی بخش‌های توسعه‌یافته را با یک شدت یکسان اجرا کنند. هر مسیر، یک یا چند بخش توسعه‌یافته را به‌صورت طبیعی برجسته می‌کند؛ برای مثال مسیر تاکسی نیویورک بر سری زمانی و رخداد، مسیر آمازون بر متن و تحلیل چندوجهی، مسیر iNaturalist بر تصویر و تغییر دامنه، و مسیر صوت بر تحلیل سیگنال و تشخیص کلیدواژه تمرکز دارد.

۱. ماهیت پروژه، پیش‌نیازها و زمان‌بندی کلی

این پروژه کاملاً **انفرادی** است. تمام مراحل شامل صورت‌بندی مسئله، انتخاب سؤال، شناخت و پاک‌سازی داده، تحلیل اکتشافی، مهندسی ویژگی، مدل‌سازی، ارزیابی، تفسیر نتایج، کدنویسی، گزارش‌نویسی، ضبط ویدیوی تحویل و دفاع شفاهی باید توسط خود دانشجو انجام شود.

شروع رسمی پروژه	۱۸ مهر ۱۴۰۵
پایان رسمی پروژه	۵ بهمن ۱۴۰۵
تعداد فازها	۵ فاز
نحوه‌ی انجام	انفرادی
محل اصلی ثبت تحویل‌ها	GitHub طبق دستورالعمل هر فاز
تحویل نهایی تکمیلی	سامانه‌ی CW طبق اطلاعیه‌ی تیم درس
زبان اصلی پیاده‌سازی	Python

چرا فقط یک پروژه؟ هر دانشجو فقط **یک مسیر پروژه** را انتخاب می‌کند و هر پنج فاز را روی همان مسیر ادامه می‌دهد. دلیل این تصمیم آن است که هر مسیر به‌تنهایی حجم کافی از کار تحلیلی، پیاده‌سازی و گزارش‌نویسی دارد و بخش قابل توجهی از مهارت‌های پایه میان مسیرها مشترک است. انجام چند مسیر به‌صورت موازی نه لازم است و نه امتیاز مستقلی ایجاد می‌کند. تغییر مسیر پس از ثبت موضوع فقط با تأیید تیم دستیاری درس امکان‌پذیر است.

۲. انتخاب مجموعه‌داده و مسیر پروژه

چهار مسیر رسمی برای پروژه تعریف شده است. هر مسیر از نظر نوع داده و مهارت‌های توسعه‌یافته متفاوت است، اما همه‌ی مسیرها باید پنج فاز اصلی را کامل کنند.

مسیر الف: NYC TLC Trip Record Data؛ داده‌ی ساخت‌یافته و سری زمانی

مسیر پایه: حداکثر ۸ نمره

مجموعه‌داده‌ی عمومی کمیسیون تاکسی و لیموزین شهر نیویورک شامل میلیون‌ها رکورد سفر تاکسی و خودروهای کرایه‌ای است. در این داده متغیرهایی مانند زمان شروع و پایان سفر، ناحیه‌ی مبدأ و مقصد، مسافت، کرایه، نوع پرداخت، تعداد مسافر و هزینه‌های جانبی وجود دارد. همین ساختار اجازه می‌دهد یک مسئله‌ی واقعی را هم از منظر داده‌ی جدولی و هم از منظر زمان و رخداد بررسی کنید.

این مسیر به‌طور مشخص **مسیر سری‌زمانی پروژه** نیز محسوب می‌شود. دانشجویی که این مسیر را انتخاب می‌کند باید علاوه بر مدل‌سازی معمول، حداقل یک تحلیل جدی وابسته به زمان مانند پیش‌بینی تقاضا، تحلیل رخداد، تشخیص ناهنجاری زمانی، بررسی تغییر الگو یا ارزیابی مدل روی بازه‌های زمانی آینده انجام دهد.

برای کنترل حجم محاسبات، تیم درس ممکن است یک بازه‌ی زمانی، یک نوع سرویس یا یک زیرمجموعه‌ی استاندارد را پیشنهاد کند. انتخاب هر زیرمجموعه باید قبل از مدل‌سازی ثبت شود و نباید بعد از مشاهده‌ی نتایج صرفاً برای بهترشدن معیارها تغییر کند.

دسترسی رسمی: NYC TLC - Trip Record Data

مسیر ب: Amazon Reviews’23؛ متن، داده‌ی ساخت‌یافته و تحلیل چندوجهی

مسیر پیشرفته و چندوجهی: تا ۱ نمره‌ی اضافی

Amazon Reviews’23 شامل نقدهای کاربران، امتیاز، زمان ثبت، رأی مفیدبودن، اطلاعات ساخت‌یافته‌ی محصول، دسته‌بندی، قیمت، توضیحات، تصویر محصول و روابط میان کاربر و کالا است. این مسیر برای تحلیل متن، پیش‌بینی امتیاز یا مفیدبودن نقد، مدل‌سازی رفتار، سیستم‌های توصیه‌گر و ترکیب چند منبع اطلاعاتی مناسب است.

برای کنترل حجم داده، دانشجو باید یک یا چند دسته‌ی محصول را با منطق روشن انتخاب کند و این انتخاب را در `PROJECT_CARD.md` ثبت کند. برای دریافت امتیاز اضافه، تحلیل باید واقعاً چندوجهی باشد؛ یعنی حداقل دو منبع اطلاعاتی متمایز مانند متن، تصویر، اطلاعات ساخت‌یافته، تاریخچه‌ی تعامل یا زمان به‌صورت معنادار وارد تحلیل شوند. صرف چسباندن چند ستون به یک جدول، تحلیل چندوجهی محسوب نمی‌شود.

دسترسی رسمی: Amazon Reviews’23 - Official Dataset Page

مسیر ج: iNaturalist Open Data؛ تصویر، مکان، زمان و داده‌ی چندوجهی

مسیر بسیار پیشرفته تا ۱ نمره‌ی اضافی

iNaturalist Open Data شامل تصاویر مشاهده‌شده از موجودات زنده به همراه اطلاعات رده‌بندی زیستی، زمان مشاهده، موقعیت جغرافیایی و فراداده‌های مرتبط است. این مسیر برای طبقه‌بندی تصویر، تحلیل long-tail ، یادگیری بازنمایی، تحلیل مکانی و زمانی، ترکیب تصویر با مکان و زمان، تشخیص نمونه‌های غیرمعمول و بررسی domain shift مناسب است.

پردازش کل مجموعه الزامی نیست. هر دانشجو باید یک زیرمجموعه‌ی علمی و قابل دفاع تعریف کند که از نظر تعداد کلاس، تعداد مشاهده و تنوع زمانی یا مکانی برای سؤال انتخابی کافی باشد. طراحی split در این مسیر بخش مهمی از مسئله است، زیرا تصاویر مرتبط با یک مشاهده، مشاهده‌گر یا مکان مشابه می‌توانند باعث نشت اطلاعات شوند.

دسترسی رسمی: AWS Registry of Open Data - iNaturalist

مسیر د: Google Speech Commands؛ تحلیل صوت و تشخیص کلیدواژه

مسیر پیشرفته‌ی صوتی: تا ۱ نمره‌ی اضافی

این مسیر برای پوشش تحلیل داده‌های صوتی طراحی شده است و مسئله‌ی پیش‌فرض آن تشخیص کلیدواژه (KWS) است: مدل باید از روی یک قطعه‌ی صوتی کوتاه تشخیص دهد چه کلیدواژه‌ای بیان شده است. مجموعه‌ی Speech Commands شامل نمونه‌های کوتاه گفتار از گویندگان مختلف است و نسخه‌ی کوچک آموزشی آن امکان انجام یک پروژه‌ی کامل با حجم محاسباتی کنترل‌شده را فراهم می‌کند.

برای مسیر رسمی درس، تیم دستیاری ممکن است زیرمجموعه‌ای کنترل‌شده از کلاس‌ها و فایل‌ها را تعیین کند؛ برای مثال چند کلیدواژه‌ی مشخص همراه با نمونه‌های سکوت یا نویز. در صورت اعلام رسمی تیم درس، یک مسئله‌ی هم‌سطح مانند speech emotion recognition نیز می‌تواند جایگزین شود، اما تغییر مسئله‌ی صوتی بدون تأیید تیم دستیاری مجاز نیست.

تمرکز این مسیر صرفاً بر آموزش یک شبکه‌ی عمیق نیست. دانشجو باید کیفیت صوت، طول نمونه، نرخ نمونه‌برداری، تفاوت گویندگان، نویز پس‌زمینه، بازنمایی‌هایی مانند MFCC یا log-mel spectrogram، طراحی speaker-disjoint split و تحلیل خطا را به‌طور جدی بررسی کند.

دسترسی رسمی و راهنمای داده: TensorFlow Datasets - Speech Commands
TensorFlow - Simple Audio Recognition Tutorial

۳. ساختار نمره و ددلاین‌ها

فاز	بازه‌ی انجام	نمره
Phase 1	۱۸ مهر تا ۱۲ آبان	۱٫۰۰
Phase 2	۱۲ آبان تا ۲۷ آبان	۱٫۲۵
Phase 3	۲۸ آبان تا ۲۷ آذر	۱٫۷۵
Phase 4	۲۷ آذر تا ۱۵ دی	۲٫۰۰
Phase 5	۱۵ دی تا ۵ بهمن	۲٫۰۰
مجموع نمره‌ی پایه	–	۸٫۰۰

برای مسیرهای سخت‌تر، امتیاز اضافه فقط زمانی تعلق می‌گیرد که الزامات مخصوص همان مسیر به‌طور کامل و قابل دفاع انجام شده باشند:

- مسیر ب، Amazon Reviews'23: تا ۱ نمره‌ی اضافی؛
- مسیر ج، iNaturalist: تا ۱٫۵ نمره‌ی اضافی؛

- مسیر د، Speech Commands : تا ۱ نمره‌ی اضافی.

۴. ثبت مسئله و جلوگیری از پروژه‌های مشابه

در ابتدای فاز اول باید فایل PROJECT_CARD.md ایجاد شود. این فایل حداقل باید شامل موارد زیر باشد:

۱. مسیر و زیرمجموعه‌ی داده‌ی انتخابی؛

۲. عنوان موقت پروژه؛

۳. مسئله‌ی واقعی یا تصمیمی که تحلیل قرار است از آن پشتیبانی کند؛

۴. واحد تحلیل و واحد پیش‌بینی؛

۵. دامنه یا جامعه‌ی هدف؛

۶. سؤال اصلی تحلیلی یا پیش‌بینی؛

۷. متغیر یا خروجی هدف، در صورت وجود؛

۸. خط مبنای اولیه؛

۹. معیارهای ارزیابی پیشنهادی؛

۱۰. طرح اولیه‌ی تقسیم آموزش، اعتبارسنجی و آزمون؛

۱۱. مهم‌ترین خطرهای نشت اطلاعات؛

۱۲. بخش بدون‌ناظر یا کشف الگوی پیشنهادی؛

۱۳. بخش توسعه‌یافته‌ی متناسب با مسیر؛

۱۴. ریسک‌های اخلاقی، حریم خصوصی یا سوگیری احتمالی.

موضوع‌ها در یک فهرست مرکزی ثبت می‌شوند. شباهت غیرعادی در سؤال اصلی، انتخاب زیرمجموعه، ساختار تحلیل، کد، ویژگی‌ها، آزمایش‌ها، متن گزارش یا نتایج می‌تواند به بررسی سلامت آموزشی و در صورت احراز همکاری غیرمجاز به نمره‌ی صفر پروژه منجر شود.

۵. فاز اول: فهم مسئله، شناخت داده، کیفیت و تحلیل اکتشافی

بازه: ۱۸ مهر تا ۱۲ آبان **نمره:** ۱۰۰/۱

هدف این فاز آن است که پیش از مدل‌سازی نشان دهید دقیقاً می‌دانید داده چگونه تولید شده، هر مشاهده نماینده‌ی چیست، چه خطاها یا سوگیری‌هایی ممکن است وجود داشته باشند و چه سؤال‌هایی واقعاً با این داده قابل پاسخ هستند.

الزامات مشترک

- **صورت‌بندی مسئله:** یک مسئله‌ی واقعی و مشخص تعریف کنید و توضیح دهید خروجی تحلیل قرار است چه تصمیم، پیش‌بینی یا بینشی را پشتیبانی کند. سؤال نباید صرفاً «بهترین مدل چیست؟» باشد.

- **شناخت منشأ داده:** منبع داده، شیوه‌ی جمع‌آوری، بازه‌ی زمانی، واحد مشاهده و محدودیت‌های اصلی تولید داده را مستند کنید. مشخص کنید داده مشاهده‌ای است یا حاصل یک فرایند کنترل‌شده.
- **ممیزی ساختار داده:** تعداد ردیف‌ها، ستون‌ها، نوع متغیرها، شناسه‌ها، متغیرهای زمانی و ارتباط جدول‌ها یا فایل‌ها را توضیح دهید. یک نمودار ساده از جریان داده یا ارتباط اجزا توصیه می‌شود.
- **ممیزی کیفیت:** مقادیر گمشده، رکوردهای تکراری، مقادیر ناممکن، ناسازگاری نوع داده و نمونه‌های پرت را کمی‌سازی کنید و برای هر مورد تصمیم اولیه‌ی خود را توضیح دهید.
- **تحلیل اکتشافی تک‌متغیره:** برای متغیرهای اصلی توزیع، مرکز، پراکندگی، عدم‌توازن و شکل توزیع را با آمارهای خلاصه و نمودار مناسب گزارش کنید.
- **تحلیل اکتشافی چندمتغیره:** حداقل چند رابطه‌ی مهم میان متغیرها را بررسی کنید و از نمودارهایی استفاده کنید که بتوانند الگو، تعامل یا تفاوت زیرگروه‌ها را آشکار کنند.
- **تعریف خطر نشت اطلاعات:** قبل از آموزش مدل توضیح دهید چه اطلاعاتی ممکن است مستقیماً یا غیرمستقیم آینده یا برچسب را افشا کند و واحد صحیح تقسیم داده چیست.
- **تعریف خط مبنا:** یک خط مبنای بسیار ساده و قابل فهم تعریف کنید تا در فازهای بعدی بتوانید نشان دهید روش‌های پیچیده‌تر واقعاً ارزش افزوده دارند.
- **سه سؤال اولیه و انتخاب سؤال نهایی:** حداقل سه سؤال قابل انجام پیشنهاد کنید و یکی را با استدلال روشن به‌عنوان سؤال اصلی ثبت کنید.

الزامات مسیر الف: NYC TLC

- **ممیزی زمان سفر:** توزیع سفرها را بر حسب ساعت، روز هفته و تاریخ بررسی کنید و دوره‌های پرترافیک، داده‌ی ناقص یا الگوهای غیرمعمول را مشخص کنید.
- **سازگاری متغیرهای سفر:** رابطه و سازگاری میان مدت سفر، مسافت، کرایه و سرعت تقریبی را بررسی کنید و رکوردهای غیرممکن یا مشکوک را مستند کنید.
- **ساخت نمای مکانی اولیه:** الگوی مبدأ و مقصد و ناحیه‌های تاکسی را خلاصه کنید و مشخص کنید آیا بعضی نواحی به‌طور نامتوازن در داده حضور دارند.
- **تعریف سؤال سری‌زمانی:** حداقل یک سؤال وابسته به زمان مانند پیش‌بینی تقاضا، تحلیل تغییر الگو یا تشخیص رخداد غیرمعمول تعریف کنید.

الزامات مسیر ب: Amazon Reviews'23

- **ممیزی اجزای چندوجهی:** مشخص کنید برای هر نمونه چه اطلاعاتی از متن نقد، امتیاز، فراداده‌ی محصول، تصویر، زمان و تعامل کاربر و کالا در دسترس است.
- **تحلیل دسترس‌پذیری هر وجه:** درصد نمونه‌هایی را که هر modality را دارند محاسبه کنید و نشان دهید نبودن تصویر، متن یا قیمت تصادفی به نظر می‌رسد یا با دسته‌ی محصول مرتبط است.

- **ممیزی متن:** توزیع طول نقد، فراوانی نقدهای بسیار کوتاه و بلند، زبان یا نویسه‌های غیرمعمول و رابطه‌ی اولیه‌ی متن با امتیاز را بررسی کنید.
- **طراحی تقسیم داده بدون نشت:** اگر مسئله به کاربر یا کالا وابسته است، توضیح دهید چرا تقسیم تصادفی ردیف‌ها ممکن است خوش‌بینانه باشد و چه واحدی برای split مناسب‌تر است.

الزامات مسیر ج: iNaturalist

- **تعریف زیرمجموعه:** کلاس‌ها، منطقه یا بازه‌ی زمانی انتخابی را قبل از مدل‌سازی مشخص کنید و دلیل علمی و محاسباتی این انتخاب را بنویسید.
- **ممیزی ساختار مشاهده:** تعداد photo، observation، observer و taxon را گزارش کنید و مشخص کنید چه تعداد تصویر ممکن است به یک مشاهده تعلق داشته باشد.
- **بررسی عدم‌توازن و دنباله‌بلند:** فراوانی کلاس‌ها را بررسی کنید و نسبت کلاس‌های پرتکرار و کم‌نمونه را گزارش دهید.
- **ممیزی مکانی و زمانی:** پراکندگی مکان و زمان را بررسی کنید و خطر استفاده‌ی ناخواسته از مکان یا فصل به‌عنوان میان‌بُر پیش‌بینی را توضیح دهید.

الزامات مسیر د: صوت و KWS

- **ممیزی فایل صوتی:** نرخ نمونه‌برداری، طول فایل، تعداد نمونه‌های هر کلاس، دامنه‌ی سیگنال و فایل‌های خراب یا بسیار کوتاه را بررسی کنید.
- **ممیزی گوینده:** شناسه‌ی گویندگان را استخراج کنید و نشان دهید هر گوینده چه تعداد نمونه در چه کلاس‌هایی دارد؛ این مرحله برای جلوگیری از نشت گوینده ضروری است.
- **بررسی نویز و سکوت:** نمونه‌های نویز پس‌زمینه، سکوت یا کلیپ‌های کم‌انرژی را شناسایی و نحوه‌ی حضور آن‌ها در مسئله‌ی طبقه‌بندی را توضیح دهید.
- **EDA صوتی:** برای چند نمونه از هر کلاس موج زمانی و یک نمایش طیفی مانند spectrogram رسم کنید و تفاوت‌های قابل مشاهده را توصیف کنید.

خروجی فاز اول

- گزارش `reports/phase1.pdf`؛
- فایل `PROJECT_CARD.md`؛
- کد قابل بازتولید برای بارگذاری و ممیزی داده؛
- `README.md` به‌روز؛
- برچسب `phase-1` در مخزن.

۶. فاز دوم: آماده‌سازی داده، مهندسی ویژگی و کشف الگو

بازه: ۱۲ آبان تا ۲۷ آبان **نمره:** ۱۲۵

در این فاز باید داده‌ی خام را به بازنمایی مناسبی برای تحلیل تبدیل کنید و پیش از ورود جدی به پیش‌بینی، ساختار پنهان داده را با روش‌های بدون‌ناظر بررسی کنید.

الزامات مشترک

- **ساخت زنجیره‌ی پیش‌پردازش:** تمام مراحل پاک‌سازی، تبدیل نوع، مدیریت مقادیر گمشده، مقیاس‌بندی و تولید ویژگی باید در یک زنجیره‌ی قابل بازاجرا پیاده‌سازی شوند؛ نه به‌صورت تغییرات دستی و غیرقابل‌ردیابی.
- **مدیریت داده‌ی گمشده:** روش برخورد با مقادیر گمشده را براساس نوع متغیر و سازوکار احتمالی نبودن داده توجیه کنید و از پرکردن کورکورانه‌ی همه‌ی مقادیر با میانگین خودداری کنید.
- **مهندسی ویژگی:** حداقل چند ویژگی جدید با منطق دامنه‌ای تولید کنید و برای هر ویژگی توضیح دهید چه اطلاعاتی اضافه می‌کند و چرا پیش از دیدن test set تعریف شده است.
- **کاهش بُعد یا ساخت بازنمایی:** حداقل یک روش مناسب مانند PCA، UMAP یا یک embedding ازپیش‌آموزش‌دیده را اجرا کنید و هدف آن را روشن کنید: مصورسازی، کاهش نویز یا ساخت ورودی مدل.
- **کشف الگو یا خوشه‌بندی:** حداقل یک روش بدون‌ناظر مانند k-means، خوشه‌بندی سلسله‌مراتبی، روش چگالی‌محور یا تحلیل embedding انجام دهید.
- **انتخاب پارامتر بدون‌ناظر:** تعداد خوشه یا پارامترهای کلیدی را با یک معیار قابل دفاع مانند silhouette، پایداری یا تحلیل کیفی انتخاب کنید؛ نه صرفاً براساس زیباترشدن نمودار.
- **پایداری الگوها:** بررسی کنید آیا خوشه‌ها یا ساختارهای کشف‌شده با تغییر seed، زیرنمونه یا مقیاس‌بندی کلی حفظ می‌شوند.
- **تفسیر الگو:** ویژگی‌های متمایز هر خوشه یا ناحیه‌ی بازنمایی را توضیح دهید و ارتباط آن را با سؤال اصلی پروژه مشخص کنید.

الزامات مسیر الف: NYC TLC

- **ویژگی‌های زمانی چرخه‌ای:** از ساعت، روز هفته و ماه ویژگی‌های مناسب بسازید و در صورت نیاز نمایش چرخه‌ای سینوس و کسینوس را با نمایش ساده‌ی عددی مقایسه کنید.
- **ویژگی‌های مکانی:** ویژگی‌های مبتنی بر ناحیه‌ی مبدأ و مقصد، فاصله یا تجمیع سطح ناحیه بسازید و توضیح دهید چه اطلاعاتی را حفظ می‌کنند.
- **خوشه‌بندی الگوهای سفر:** سفرها، نواحی یا بازه‌های زمانی را براساس تقاضا، مدت، مسافت یا الگوی رفت‌وآمد خوشه‌بندی و خوشه‌ها را نام‌گذاری و تفسیر کنید.

- **نامزدهای ناهنجاری:** نمونه‌هایی با زمان، کرایه، سرعت یا تقاضای غیرمعمول را شناسایی کنید و تفاوت خطای داده با رخداد واقعی را توضیح دهید.

الزامات مسیر ب: Amazon Reviews'23

- **بازنمایی متن:** حداقل یک بازنمایی کلاسیک مانند TF-IDF و در صورت امکان یک embedding متنی را بسازید و تفاوت کاربرد آن‌ها را توضیح دهید.
- **ویژگی‌های ساخت‌یافته:** ویژگی‌هایی مانند دسته‌ی محصول، قیمت، طول نقد، سن نقد، امتیاز و شاخص‌های تعامل را به شکل مناسب آماده کنید.
- **بازنمایی وجه دوم:** اگر تصویر یا وجه دیگری استفاده می‌شود، embedding آن را با یک مدل ازپیش‌آموزش‌دیده استخراج کنید و بدون نیاز به آموزش مدل بزرگ از صفر ذخیره و مستند کنید.
- **کشف الگو در نقد یا محصول:** نقدها یا محصولات را براساس بازنمایی انتخابی خوشه‌بندی کنید و بررسی کنید خوشه‌ها با دسته‌ی محصول، امتیاز یا رفتار کاربر چه رابطه‌ای دارند.

الزامات مسیر ج: iNaturalist

- **استخراج embedding تصویری:** برای تصاویر زیرمجموعه یک بازنمایی معتبر از یک مدل ازپیش‌آموزش‌دیده استخراج کنید و نسخه‌ی مدل و تنظیمات پیش‌پردازش را ثبت کنید.
- **تحلیل فضای بازنمایی:** با کاهش بُعد، ساختار embedding را مصورسازی و ارتباط آن را با taxonomy ، مکان یا فصل بررسی کنید.
- **تحلیل دنباله‌بلند:** نشان دهید imbalance چگونه روی نمای داده و خوشه‌ها اثر دارد و چه کلاس‌هایی در فضا با یکدیگر مخلوط می‌شوند.
- **نمونه‌های غیرمعمول:** نمونه‌های دورافتاده یا بالقوه خارج از توزیع را شناسایی و به‌صورت کیفی بررسی کنید که خطای برچسب، کیفیت پایین یا تفاوت زیستی هستند.

الزامات مسیر د: صوت و KWS

- **یکنواخت‌سازی سیگنال:** همه‌ی فایل‌ها را به نرخ نمونه‌برداری و طول هدف یکسان تبدیل کنید و شیوه‌ی padding/cropping را مستند کنید.
- **ساخت ویژگی صوتی:** حداقل یک بازنمایی مانند MFCC یا log-mel spectrogram بسازید و پارامترهایی مانند اندازه پنجره، hop length و تعداد باندها را گزارش کنید.
- **افزایش داده‌ی کنترل‌شده:** در صورت استفاده از time shift ، gain ، افزودن نویز یا سایر augmentation ها، شدت آن‌ها را ثبت کنید و augmentation را فقط روی داده‌ی آموزشی اعمال کنید.
- **کشف الگو در صدا:** روی MFCC ، embedding یا ویژگی‌های طیفی کاهش بُعد یا خوشه‌بندی انجام دهید و بررسی کنید آیا کلاس‌ها، گویندگان یا شرایط نویزی ساختار قابل مشاهده‌ای ایجاد می‌کنند.

خروجی فاز دوم

- گزارش فاز دوم؛
- کد یا pipeline آماده‌سازی داده؛
- شکل‌های کاهش بُعد و خوشه‌بندی؛
- فهرست ویژگی‌های ساخته‌شده و منطق آن‌ها؛
- برچسب phase-2.

۷. فاز سوم: مدل‌سازی پیش‌بینانه و طراحی آزمایش

بازه: ۲۸ آبان تا ۲۷ آذر **نمره:** ۱۷۵

هدف این فاز ساخت مدل‌هایی است که تحت یک طراحی ارزیابی معتبر سنجیده شوند، نه اینکه صرفاً روی یک تقسیم تصادفی عدد خوبی تولید کنند.

الزامات مشترک

- **تعریف هدف پیش‌بینی یا تصمیم:** متغیر هدف، واحد پیش‌بینی، زمان در دسترس بودن ویژگی‌ها و کاربرد خروجی مدل را دقیق تعریف کنید.
- **ساخت baseline ساده:** یک مدل یا قاعده‌ی بسیار ساده بسازید؛ برای مثال میانگین یا میانه، majority class یا یک مدل خطی ساده.
- **طراحی ارزیابی:** train/validation/test یا cross-validation را متناسب با وابستگی‌های داده طراحی کنید. اگر زمان، گوینده، کاربر، کالا یا مشاهده ساختار گروهی ایجاد می‌کند، تقسیم باید آن را رعایت کند.
- **جلوگیری از نشت در پیش‌پردازش:** هر آماری که از داده یاد گرفته می‌شود، شامل imputation ،scaling ، feature selection و vocabulary، باید فقط از داده‌ی آموزشی هر fold محاسبه شود.
- **مقایسه‌ی چند خانواده‌ی مدل:** حداقل سه خانواده‌ی مدل، شامل baseline ساده، مقایسه شوند. پیچیدگی مدل‌ها باید با اندازه و ماهیت داده تناسب داشته باشد.
- **تنظیم hyperparameter:** پارامترها فقط با داده‌ی آموزش و اعتبارسنجی تنظیم شوند و test set تا پایان قفل بماند. فضای جست‌وجو و معیار انتخاب مدل ثبت شود.
- **معیارهای چندگانه:** برای رگرسیون حداقل معیارهایی مانند MAE/RMSE/R2 و برای طبقه‌بندی معیارهای متناسب مانند precision/recall/F1/ROC-AUC/PR-AUC گزارش شوند.
- **عدم قطعیت یا تغییرپذیری:** با تکرار ارزیابی، bootstrap یا گزارش پراکندگی foldها نشان دهید یک تفاوت کوچک در metric تا چه حد قابل اتکاست.
- **تحلیل خطا:** نمونه‌های خطای بزرگ یا الگوهای شکست سیستماتیک را استخراج و دسته‌بندی کنید.

الزامات مسیر الف: NYC TLC

- **مسئله‌ی پیش‌بینی اصلی:** حداقل یک مسئله‌ی رگرسیون یا forecasting مانند پیش‌بینی مدت سفر، کرایه یا تقاضای یک بازه‌ی زمانی بسازید.
- **تقسیم زمانی:** برای مسئله‌ای که از زمان استفاده می‌کند، داده‌ی آینده نباید وارد آموزش گذشته شود؛ بنابراین یک split زمانی و دلیل انتخاب مرز آن ارائه کنید.
- **مدل ساده در برابر غیرخطی:** یک مدل خطی یا ساده را با حداقل یک مدل غیرخطی یا ensemble مقایسه کنید و تفاوت آن‌ها را روی زیرگروه‌ها بررسی کنید.
- **ارزیابی در نواحی مختلف:** عملکرد را در چند zone یا بازه‌ی زمانی گزارش کنید تا مشخص شود یک metric کلی ضعف محلی را پنهان نکرده است.

الزامات مسیر ب: Amazon Reviews'23

- **baseline ساخت‌یافته:** مدلی فقط با metadata/ویژگی‌های عددی و دسته‌ای بسازید.
- **baseline متنی:** مدلی فقط با متن یا embedding متنی بسازید تا ارزش واقعی متن مستقل از سایر وجوه سنجیده شود.
- **مدل ترکیبی:** حداقل دو modality را به‌صورت معنادار ادغام کنید و روش fusion را توضیح دهید.
- **تقسیم امن کاربر یا کالا:** در مسائل وابسته به کاربر یا محصول، نشان دهید طراحی split مانع افشای اطلاعات آینده یا نمونه‌های بسیار مشابه می‌شود.
- **تحلیل افزوده شدن modality:** گزارش کنید اضافه شدن وجه دوم نسبت به baseline تک‌وجهی چه تغییری ایجاد کرده و آیا این تغییر در همه‌ی دسته‌ها پایدار است.

الزامات مسیر ج: iNaturalist

- **baseline تصویری:** یک baseline معتبر با embedding ثابت یا مدل سبک تصویری بسازید.
- **baseline فراداده:** مدلی فقط با زمان، مکان یا metadata مرتبط ایجاد کنید تا میان‌بُرهای غیرتصویری آشکار شوند.
- **تقسیم گروهی:** split را در سطح observation و در صورت لزوم observer/location انجام دهید و منطق آن را ثبت کنید.
- **معیارهای long-tail:** علاوه بر معیار کلی، metric macro و عملکرد rare-class/per-class را گزارش کنید.
- **کالیبراسیون خطاهای نادر:** بررسی کنید مدل روی کلاس‌های کم‌نمونه تا چه حد بیش‌اطمینان است و چند مورد خطای شاخص را تحلیل کنید.

الزامات مسیر د: صوت و KWS

- **split مستقل از گوینده:** هیچ گوینده‌ای نباید هم‌زمان در train و test حضور داشته باشد. شناسه‌های گوینده و منطق تقسیم را ذخیره کنید.
- **baseline کلاسیک:** یک baseline ساده، برای مثال logistic regression یا SVM روی MFCC، بسازید تا ارزش روش پیچیده‌تر قابل سنجش باشد.
- **مدل صوتی اصلی:** حداقل یک مدل مناسب روی embedding/spectrogram، مانند CNN کوچک یا مدل ازپیش‌آموزش‌دیده‌ی سبک، پیاده‌سازی کنید.
- **معیارهای کلاس‌محور:** macro-F1، recall هر کلیدواژه و confusion matrix را گزارش کنید؛ accuracy به‌تنهایی کافی نیست.
- **ارزیابی نویز:** حداقل یک ارزیابی کنترل‌شده در حضور نویز یا تغییر gain انجام دهید و افت عملکرد را نسبت به شرایط تمیز گزارش کنید.

خروجی فاز سوم

- گزارش benchmark کامل؛
- جدول baseline ها و مدل‌های اصلی؛
- کد قابل بازتولید training/evaluation؛
- فایل پیکربندی یا ثبت hyperparameter ها؛
- برچسب phase-3.

۸. فاز چهارم: تفسیرپذیری، تحلیل توسعه‌یافته و تصمیم‌گیری

بازه: ۲۷ آذر تا ۱۵ دی **نمره:** ۲٫۰۰

در این فاز باید از «مدل با عملکرد خوب» عبور کنید و نشان دهید مدل چه چیزی یاد گرفته، در کجا شکست می‌خورد، نتیجه چقدر حساس است و چگونه می‌توان آن را به یک بینش یا تصمیم معتبر تبدیل کرد.

الزامات مشترک

- **تفسیر کلی مدل:** حداقل یک روش global interpretability مانند coefficient analysis، permutation importance، SHAP یا روش مناسب داده‌ی خود اجرا و با احتیاط تفسیر کنید.
- **تفسیر نمونه‌ای:** چند مورد مشخص از پیش‌بینی درست، خطای قابل توجه و نمونه‌ی مرزی را در سطح case بررسی کنید.
- **تحلیل حساسیت:** حداقل یک تصمیم مهم در pipeline را تغییر دهید و بررسی کنید نتیجه به انتخاب خاص شما وابسته است یا خیر؛ برای مثال تعریف ویژگی، preprocessing، threshold یا نوع مدل.

- **عملکرد زیرگروه:** حداقل دو زیرگروه معنادار را از نظر عملکرد مقایسه کنید و علت احتمالی اختلاف را بررسی کنید.
- **تمایز همبستگی و علیت:** صریحاً مشخص کنید کدام یافته‌ها صرفاً ارتباط پیش‌بینانه‌اند و چه چیزی برای ادعای علّی کم است.
- **تبدیل نتیجه به تصمیم:** یک سناریوی واقعی تعریف کنید که در آن نتیجه‌ی مدل به تصمیم یا insight تبدیل می‌شود و هزینه‌ی خطاهای مختلف را توضیح دهید.

مسیر الف: مؤلفه‌ی سری زمانی و رخداد

حداقل دو مورد از موارد زیر باید به‌صورت جدی انجام شوند:

- **Forecasting:** یک کمیت زمانی را با split آینده‌نگر پیش‌بینی و با baseline فصلی/ساده مقایسه کنید.
- **تحلیل رخداد:** تغییر رفتار پیرامون یک رخداد زمانی قابل تعریف را بررسی کنید؛ بدون ادعای علّی مگر در صورت وجود طراحی مناسب.
- **تشخیص ناهنجاری:** دوره‌ها یا نواحی غیرعادی را با روش روشن شناسایی و نمونه‌ها را به خطای داده یا رخداد واقعی تفکیک کنید.
- **Temporal shift:** عملکرد مدل را در ماه‌ها یا بازه‌های آینده مقایسه کنید تا افت ناشی از تغییر توزیع روشن شود.
- **Spatiotemporal analysis:** زمان و مکان را هم‌زمان در تحلیل الگو یا خطا وارد کنید.

مسیر ب: مؤلفه‌ی متن و چندوجهی

حداقل دو مورد از موارد زیر باید انجام شوند:

- **Multimodal fusion:** دو یا چند وجه را ادغام و با مدل‌های تک‌وجهی مقایسه کنید.
- **Sentiment یا aspect analysis:** ساختار معنایی متن را فراتر از امتیاز خام بررسی کنید و نمونه‌های ناسازگار متن/امتیاز را تحلیل کنید.
- **Modality ablation:** هر modality را جداگانه حذف کنید تا سهم واقعی آن روشن شود.
- **رفتار زمانی:** تغییر زبان نقد، امتیاز یا رفتار محصول/کاربر را در زمان بررسی کنید.
- **استفاده‌ی کنترل‌شده از LLM:** در صورت استفاده از LLM برای استخراج ویژگی یا برچسب‌گذاری کمکی، baseline غیر-LLM، پروتکل ثابت و اعتبارسنجی انسانی/نمونه‌ای ارائه کنید.

مسیر ج: مؤلفه‌ی تصویر و تغییر دامنه

حداقل دو مورد از موارد زیر باید انجام شوند:

- **fusion metadata + Image**: تصویر را با زمان یا مکان یا metadata ادغام و نسبت به baseline های جداگانه ارزیابی کنید.
- **temporal shift Geographic/**: یک ناحیه یا دوره را برای ارزیابی نگه دارید و تعمیم مدل را بررسی کنید.
- **Long-tail analysis**: خطاهای کلاس‌های کم‌نمونه را جداگانه بررسی و یک راهکار معقول برای عدم‌توازن آزمایش کنید.
- **OOD analysis**: نمونه‌های خارج از توزیع یا atypical را با روش مشخص پیدا و به‌صورت کیفی بررسی کنید.
- **Representation ablation**: بازنمایی یا مدل تصویری جایگزین را مقایسه کنید تا نتیجه فقط به یک encoder وابسته نباشد.

مسیر د: مؤلفه‌ی صوت، نویز و گوینده

حداقل دو مورد از موارد زیر باید انجام شوند:

- **robustness Noise**: سطوح مشخصی از نویز را اضافه کنید و منحنی افت عملکرد را در چند سطح شدت گزارش کنید.
- **Speaker generalization**: عملکرد را بین گویندگان دیده‌نشده و در صورت امکان زیرگروه‌های مختلف گوینده مقایسه کنید.
- **Unknown/Silence analysis**: اگر کلاس unknown یا silence وجود دارد، false positive های مهم را تحلیل کنید؛ در کاربرد KWS این خطاها اهمیت عملی بالایی دارند.
- **Feature ablation**: MFCC، log-mel یا embedding انتخابی را با یکدیگر یا با حذف augmentation مقایسه کنید.
- **تحلیل موردی spectrogram**: چند خطای شاخص را در spectrogram/waveform بررسی کنید و توضیح دهید آیا خطا ناشی از نویز، شباهت آوایی یا کیفیت ضبط است.

خروجی فاز چهارم

- گزارش تحلیل توسعه‌یافته؛
- جدول sensitivity، subgroup و ablation؛
- مصورسازی‌های تفسیرپذیری یا تحلیل خطا؛
- برچسب phase-4.

۹. فاز پنجم: استحکام، مطالعه‌ی موردی واقعی و نسخه‌ی نهایی

بازه: ۱۵ دی تا ۵ بهمن **نمره:** ۲٫۰۰

هدف فاز پنجم این است که همه‌ی اجزای پروژه را به یک مطالعه‌ی منسجم تبدیل کنید: سؤال مشخص، داده‌ی قابل دفاع، baseline های منصفانه، ارزیابی سخت‌گیرانه، تحلیل خطا، استحکام و نتیجه‌گیری محدود به شواهد واقعی.

۱.۹. مرور کارهای مرتبط

حداقل چند منبع واقعاً مرتبط و جدید را بررسی کنید. برای هر منبع، مسئله، داده، روش، معیار ارزیابی و محدودیت مهم را در یک جدول خلاصه کنید. هدف این بخش ادعای اجباری «نوآوری» نیست؛ هدف آن است که بدانید راه‌حل شما در مقایسه با روش‌های رایج چه جایگاهی دارد و چرا طراحی انتخابی شما معقول است.

۲.۹. الزامات نهایی مشترک

- **بازاجرای کامل از ابتدا:** از دریافت یا بارگذاری داده تا شکل‌ها و جداول نهایی باید با دستورالعمل مخزن قابل بازاجرا باشد.
- **Baseline های منصفانه:** نسخه‌ی نهایی باید baseline های ساده و قوی را کنار روش اصلی نگه دارد؛ حذف baseline ضعیف‌کننده‌ی استدلال است.
- **Ablation واقعی:** حداقل یک جزء مهم مانند modality، family feature، augmentation یا مرحله‌ی pipeline را حذف کنید و اثر آن را گزارش کنید.
- **Robustness:** حداقل چند آزمایش حساسیت واقعی انجام دهید؛ تغییر صرف seed به‌تنهایی robustness محسوب نمی‌شود.
- **Uncertainty-aware comparison:** در صورت امکان تفاوت مدل‌ها را با تکرار ارزیابی، interval یا روش آماری مناسب همراه کنید تا تفاوت‌های کوچک بیش‌تفسیر نشوند.
- **Error taxonomy:** خطاها را به چند نوع قابل تفسیر تقسیم کنید و سهم یا نمونه‌ی هر نوع را گزارش کنید.
- **Distribution shift:** اگر داده ساختار زمانی، مکانی، گوینده‌ای، کاربر یا کالا یا کلاس‌های متفاوت دارد، حداقل یک سناریوی shift معنادار بررسی کنید.
- **Ethics و governance:** محدودیت‌های استفاده، سوگیری، حریم خصوصی، مجوز داده و خطر استفاده‌ی نادرست از مدل را صریح گزارش کنید.
- **جمع‌بندی تصمیم‌محور:** نتیجه‌گیری باید بگوید از داده چه چیزی آموخته‌ایم، کجا اطمینان نداریم و برای کاربرد واقعی چه شرط‌هایی لازم است.

۳.۹. الزامات نهایی مسیر الف

حداقل دو مورد: تعمیم زمانی، تعمیم در zone ها، forecasting under shift، anomaly robustness ، ارزیابی پیش و پس یک رخداد به‌صورت توصیفی، یا افزودن یک منبع عمومی خارجی با مستندسازی کامل.

۴.۹. الزامات نهایی مسیر ب

حداقل موارد زیر: مقایسه‌ی structured-only، text-only و multimodal؛ modality ablation؛ یک ارزیابی temporal یا cold-start؛ تحلیل failure case های متن یا تصویر؛ و در صورت استفاده از LLM، مقایسه با baseline غیر‌ـ LLM و ثبت prompt/protocol.

۵.۹. الزامات نهایی مسیر ج

حداقل موارد زیر: image-only در برابر metadata-only در برابر multimodal؛ تعمیم جغرافیایی یا زمانی؛ تحلیل long-tail؛ calibration یا uncertainty؛ ممیزی leakage مربوط به observer/location؛ و modality/representation ablation.

۶.۹. الزامات نهایی مسیر د

حداقل موارد زیر: baseline کلاسیک در برابر مدل صوتی اصلی؛ speaker-disjoint evaluation؛ ارزیابی در شرایط نویزی؛ confusion/error taxonomy؛ حداقل یک feature یا augmentation ablation؛ و تحلیل جداگانه‌ی false positive/false negative های مهم در KWS.

خروجی فاز پنجم

- گزارش نهایی؛
- کد و notebook های نهایی قابل بازاجرا؛
- جداول، شکل‌ها و فایل‌های supplementary موردنیاز؛
- فایل `AI_USAGE.md`؛
- ویدیوی اجباری تحویل نهایی طبق بخش ۱۶؛
- برچسب `phase-5-final`.

۱۰. ساختار گزارش نهایی

گزارش نهایی باید حداقل شامل بخش‌های زیر باشد:

۱. Abstract؛

۲. Problem Definition and Motivation؛

۳. Related Work؛

۴. Data and Data Quality؛

۵. Exploratory Analysis؛

۶. Methods؛

۷. Experimental Design؛

۸. Results؛

۹. Interpretability and Error Analysis؛

۱۰. Robustness / Sensitivity / Shift Analysis؛

۱۱. Ethics, Privacy and Governance؛

۱۲. Discussion؛

۱۳. Limitations؛

۱۴. Conclusion؛

۱۵. References؛

۱۶. Supplementary Material.

شکل‌ها و جداول باید خوانا و مستقل از خروجی خام کتابخانه باشند. screenshot خام از terminal یا notebook به‌عنوان شکل نهایی قابل قبول نیست مگر اینکه خود screenshot موضوع تحلیل باشد.

۱۱. بازتولیدپذیری، کدنویسی و GitHub

GitHub مرجع اصلی روند پروژه است. تمام خروجی‌های هر فاز باید تا ددلاین در مخزن قرار بگیرند و تاریخ commit/tag ملاک اصلی بررسی روند کار خواهد بود.

ساختار پیشنهادی:

```
README.md
PROJECT_CARD.md
AI_USAGE.md
configs/
data/
    README.md
src/
notebooks/
figures/
models/
reports/
    phase1/
    phase2/
    phase3/
    phase4/
    final/
requirements.txt
```

```
# or environment.yml / pyproject.toml
```

قواعد اصلی:

- داده‌های بزرگ داخل GitHub آپلود نشوند؛
- مسیر دریافت داده یا ساخت subset مستند باشد؛
- seed های اصلی ثبت شوند؛
- preprocessing و feature engineering قابل بازاجرا باشند؛
- training/evaluation از notebook های صرفاً اکتشافی تا حد امکان جدا باشند؛
- در پایان هر فاز tag متناظر ایجاد شود.

علاوه بر GitHub، در سامانه‌ی CW یک محل تحویل نهایی باز خواهد شد. در آنجا باید فایل ZIP شامل PDF گزارش، کدها، notebook ها، فایل‌های پیکربندی و سایر اقلام اعلام‌شده بارگذاری شود. تحویل در CW جایگزین GitHub نیست؛ هر دو بخش برای تحویل نهایی لازم‌اند.

۱۲. سیاست استفاده از هوش مصنوعی و مدل‌های زبانی بزرگ

از آنجا که AI/LLM بخشی از سرفصل درس است، استفاده‌ی شفاف و قابل ارزیابی از این ابزارها مجاز است. فایل AI_USAGE.md برای همه‌ی دانشجویان الزامی است و باید حداقل نام ابزار، هدف استفاده، prompt/protocol اصلی در صورت استفاده‌ی تحلیلی، نحوه‌ی اعتبارسنجی و محدودیت‌ها را ثبت کند.

اگر LLM/VLM بخشی از روش پروژه است، باید مانند هر مدل دیگر baseline، evaluation و در صورت امکان ablation داشته باشد. استفاده از خروجی تولیدشده بدون فهم و توانایی دفاع از آن پذیرفته نیست.

۱۳. حریم خصوصی، اخلاق و حاکمیت داده

هر پروژه باید یک بخش کوتاه اما دقیق درباره‌ی privacy، ethics و governance داشته باشد. حداقل باید اطلاعات حساس بالقوه، محدودیت مجوز داده، سوگیری نمونه، محدودیت کاربرد مدل و خطر ادعای علّی بدون طراحی مناسب بررسی شوند. تلاش برای deanonymization یا استخراج هویت واقعی اشخاص از شناسه‌های ناشناس مجاز نیست.

در مسیر آمازون شناسه‌ی کاربر صرفاً یک شناسه‌ی تحلیلی است. در مسیر iNaturalist استفاده از اطلاعات مشاهده‌گر برای شناسایی فرد مجاز نیست. در مسیر صوت نیز تلاش برای شناسایی هویت گوینده خارج از سؤال مجاز نیست و شناسه‌ی گوینده فقط برای طراحی split و تحلیل تعمیم استفاده می‌شود.

۱۴. اصالت کار و شباهت پروژه‌ها

پروژه کاملاً انفرادی است. شباهت معنادار و غیرعادی در سؤال، subset، pipeline، کد، ویژگی‌ها، آزمایش‌ها، متن گزارش، شکل‌ها، جداول یا notebook structure بررسی می‌شود. کدهای starter منتشرشده توسط تیم درس مستثنی هستند. دانشجو باید بتواند تمام تصمیم‌های پروژه را در دفاع شفاهی توضیح دهد.

۱۵. اصول علمی ارزیابی پروژه

نمره‌ی پروژه وابسته به بالاترین accuracy نیست. یک مدل ساده با طراحی آزمایش صحیح و تحلیل خطای قوی می‌تواند از یک مدل پیچیده با leakage یا ارزیابی ضعیف نمره‌ی بیشتری بگیرد.

موارد غیرقابل قبول شامل استفاده از test set برای tuning، data leakage، حذف نتایج ضعیف بدون گزارش، اجرای تعداد زیادی مدل و گزارش صرف بهترین مورد بدون protocol، تغییر سؤال بعد از دیدن نتیجه بدون اعلام exploratory بودن، انتخاب metric برای بهتر نشان‌دادن مدل و ادعای causal صرفاً براساس correlation است.

۱۶. ویدیوی اجباری برای تحویل پروژه

علاوه بر گزارش و کد، **هر دانشجو موظف است یک ویدیوی ضبط‌شده از معرفی و توضیح پروژه را به‌عنوان بخشی از submission نهایی تحویل دهد.** این ویدیو مستقل از ارائه و دفاع شفاهی بخش ۱۷ است و جایگزین آن نمی‌شود.

ویدیو باید حداقل موارد زیر را پوشش دهد:

- **تعریف مسئله:** در ابتدای ویدیو سؤال اصلی و دلیل اهمیت آن را در چند جمله روشن توضیح دهید.
- **معرفی داده و pipeline:** داده‌ی استفاده‌شده، subset، مهم‌ترین مراحل preprocessing و طراحی split را توضیح دهید.
- **آزمایش‌های اصلی:** baseline، مدل اصلی، معیارهای ارزیابی و مهم‌ترین نتیجه‌ها را نشان دهید.
- **تحلیل خطا و محدودیت:** حداقل یک failure mode و یک محدودیت واقعی پروژه را توضیح دهید.
- **بازتولیدپذیری:** ساختار GitHub و محل کد اصلی یا notebookهای کلیدی را به‌اختصار نشان دهید.

مدت، فرمت فایل، شیوه‌ی نام‌گذاری و روش بارگذاری ویدیو متعاقباً توسط تیم درس اعلام خواهد شد. تحویل نهایی بدون ویدیوی خواسته‌شده ناقص محسوب می‌شود.

۱۷. ارائه و دفاع شفاهی

پس از اتمام پروژه، همه‌ی دانشجویان ارائه و دفاع شفاهی خواهند داشت. زمان، مدت، ترتیب و افراد ارزیابی‌کننده متعاقباً اعلام می‌شوند. در جلسه ممکن است درباره‌ی صورت‌بندی مسئله، کیفیت داده، preprocessing، fea-ture engineering، split، baseline، انتخاب مدل، tuning، metrics، interpretability، error analysis، leakage، robustness، AI/LLM، محدودیت‌ها و کد سؤال شود.

ممکن است از دانشجو خواسته شود یک بخش از کد را توضیح دهد، یک نمودار را تفسیر کند یا توضیح دهد اگر یک فرض، feature یا split تغییر کند چه اتفاقی برای نتیجه می‌افتد. توانایی دفاع از تصمیم‌ها بخشی از ارزیابی پروژه است.

۱۸. تغییر احتمالی بارم

در صورتی که شیوه‌ی برگزاری آزمون‌های درس تغییر کند، ممکن است سهم پروژه در نمره‌ی نهایی درس نیز تغییر کند.

هرگونه تغییر پیش از اعمال از کانال رسمی درس اعلام خواهد شد.

۱۹. جمع‌بندی

هدف پروژه تحویل یک notebook طولانی یا صرفاً ثبت بهترین metric نیست. پروژه‌ی قوی باید مسئله را درست تعریف کند، داده را بشناسد، pipeline بازتولیدپذیر داشته باشد، از leakage جلوگیری کند، baseline منصفانه داشته باشد، طراحی آزمایش معتبر انجام دهد، uncertainty و failure mode را گزارش کند، میان correlation و causality تمایز بگذارد، اخلاق و حریم خصوصی را جدی بگیرد و در نهایت تمام تصمیم‌ها را در ویدیو و دفاع شفاهی توضیح دهد.